

Python de Extremo a Extremo

Automatización, Análisis Geoespacial y Visión Artificial

Tomás Valderrama

Índice

1	Python de Extremo a Extremo	6
1.1	Contenidos	6
1.2	Requisitos	6
1.3	Cómo usar este manual	6
2	Entorno Spyder	7
2.1	Instalación	7
2.2	La interfaz de Spyder	7
2.3	Ejecutar código	7
2.4	Atajos de edición esenciales	7
2.5	Celdas de código	8
2.6	Variable Explorer	8
2.7	Consola IPython	8
2.8	Configuración recomendada	9
3	Sintaxis básica	10
3.1	Variables y tipos	10
3.2	Strings (texto)	12
3.3	Listas	12
3.4	Diccionarios	13
3.5	Indentación	13
3.6	Comentarios	13
3.7	Operadores	14
3.8	Conversión de tipos	14
4	Control de flujo	15
4.1	Condicionales: if / elif / else	15
4.2	Bucles: for	15
4.3	Bucles: while	16
4.4	break y continue	16
4.5	List comprehensions	16
4.6	Manejo de errores: try / except	17
4.7	Combinando estructuras	18

5	Funciones y módulos	21
5.1	Funciones	21
5.2	Módulos e imports	23
5.3	Organizar código en módulos	24
5.4	Scope (alcance de variables)	24
6	NumPy	26
6.1	Arrays vs listas de Python	26
6.2	Arrays	26
6.3	Operaciones vectorizadas y broadcasting	27
6.4	Indexación y slicing	28
6.5	Estadísticas	28
6.6	Funciones trigonométricas	29
6.7	NaN — valores faltantes	29
6.8	Operaciones útiles	30
7	Pandas	31
7.1	Series y DataFrames	31
7.2	Explorar un DataFrame	31
7.3	Acceder a datos	31
7.4	Filtrado	32
7.5	Series temporales	32
7.6	Operaciones por columna	33
7.7	Estadísticas	33
7.8	groupby — estadísticas por categoría	34
7.9	pivot_table — tabla de frecuencias	34
7.10	merge y concat — combinar DataFrames	35
7.11	Manejar NaN	35
7.12	Leer y guardar datos	35
8	Lectura de archivos	36
8.1	Archivos de texto y CSV	36
8.2	Archivos Excel	36
8.3	Archivos MATLAB (.mat)	37
8.4	Archivos JSON	38
8.5	Archivos de texto plano	38
8.6	Buscar archivos con glob y os	38
8.7	Documentos Word (.docx)	39
8.8	Manejo de rutas con pathlib	40
9	Matplotlib	41
9.1	Gráfico básico	41
9.2	Figure y Axes — la estructura correcta	41
9.3	Múltiples paneles	42
9.4	Tipos de gráfico	42
9.5	Colores y estilos	44
9.6	Ejes y etiquetas	44
9.7	Leyenda y anotaciones	45

9.8	Mapas de calor (heatmap)	45
9.9	Guardar figuras	45
9.10	Figuras con valores calculados	46
9.11	Backend gráfico	49
10	Rosas de viento y diagramas polares	50
10.1	Rosa de viento con windrose	50
10.2	Rosa de corrientes (sin windrose)	50
10.3	Diagrama polar de dispersión	51
10.4	Vector progresivo	52
10.5	Patrón diurno	53
11	Figuras para informes	54
11.1	Estilo consistente	54
11.2	Guardar con calidad para informe	54
11.3	Nomenclatura de archivos de figura	55
11.4	Figuras por profundidad	55
11.5	Ciclo anual mensual	55
11.6	Insertar figuras en Word	56
11.7	Figura multipanel para series de oleaje	56
12	Estadísticas circulares	58
12.1	Media y desviación estándar circular	58
12.2	Dirección predominante	59
12.3	Diferencia angular	59
12.4	Error cuadrático medio circular	59
12.5	Estadísticas por sector en el pipeline	59
12.6	Histograma direccional	60
13	Análisis espectral	62
13.1	Transformada de Fourier con NumPy	62
13.2	Densidad espectral de potencia con Welch	62
13.3	Espectro de oleaje	63
13.4	Visualizar el espectro de oleaje	64
13.5	Identificar componentes de marea	64
13.6	Espectrograma (espectro en tiempo)	65
14	Filtros e interpolación	66
14.1	Media móvil (filtro de paso bajo simple)	66
14.2	Filtro Butterworth (scipy)	66
14.3	Interpolación de NaN	67
14.4	Remuestreo temporal	68
14.5	Detección y eliminación de spikes	69
14.6	Comparar señal original y filtrada	69
15	python-docx	71
15.1	Instalación	71
15.2	Estructura de un documento .docx	71
15.3	Abrir y guardar	71

15.4	Leer contenido	71
15.5	Reemplazar texto en párrafos	72
15.6	Insertar figuras	72
15.7	Construir tablas	73
15.8	Aplicar formato a texto	73
15.9	Iterar sobre cuerpo completo (párrafos + tablas)	74
15.10	Flujo completo del autoinforme	74
16	Plantillas y placeholders	76
16.1	Convención de placeholders	76
16.2	Validar que todos los placeholders se reemplazaron	76
16.3	Placeholders en tablas	76
16.4	Placeholders que se repiten	77
16.5	Placeholder partido entre runs	77
16.6	Diccionario de reemplazos por campaña	78
16.7	Flujo recomendado	79
17	Importación dinámica	80
17.1	El problema: configuración por proyecto	80
17.2	importlib.import_module	80
17.3	Estructura de un módulo de configuración	81
17.4	Verificar que el módulo tiene los atributos necesarios	81
17.5	Recargar un módulo modificado	82
17.6	Listar proyectos disponibles	82
17.7	Patrón del script central	82
18	Rasterio y GeoPandas	84
18.1	Instalación	84
18.2	Leer un raster con rasterio	84
18.3	Obtener coordenadas de la grilla	84
18.4	Extraer el valor en un punto	85
18.5	Leer un shapefile con GeoPandas	85
18.6	Crear un GeoDataFrame desde coordenadas	85
18.7	Reproyectar	86
18.8	Operaciones espaciales básicas	86
18.9	Exportar resultados	86
18.10	Estadísticas zonales	87
19	Coordenadas y mapas	88
19.1	Conversión UTM $\leftrightarrow$ lat/lon con pyproj	88
19.2	Mapa de contexto con GeoPandas y Matplotlib	88
19.3	Mapa de fondo con contextily (imágenes de satélite/OpenStreetMap)	90
19.4	Grilla de campo vectorial (corrientes)	90
19.5	Recortar raster a área de estudio	91
19.6	Calcular distancia a la costa	91
20	OCR de cartas batimétricas	93
20.1	Dependencias	93
20.2	Flujo general del pipeline	93

20.3	Cargar y preprocesar la imagen	93
20.4	Detectar regiones candidatas	94
20.5	OCR con Tesseract	95
20.6	Deduplicar sondeos solapados	97
20.7	Georeferencia	97
20.8	Exportar a CSV y XYZ	98
20.9	Visualizar resultado	98
21	Outputs de CROCO-ROMS	100
21.1	Instalación	100
21.2	Abrir un archivo y explorar su estructura	100
21.3	Coordenadas verticales sigma	101
21.4	Mapa de temperatura superficial	101
21.5	Serie temporal en un punto	101
21.6	Perfil vertical: convertir sigma a metros	102
21.7	Sección transversal	103
22	Sentinel-2: API STAC de Copernicus y análisis de cobertura MGRS	105
22.1	El sistema de tiles MGRS	105
22.2	La API STAC de Copernicus	105
22.3	Buscar imágenes en un área	105
22.4	Extraer metadatos de cada imagen	106
22.5	Descarga masiva de metadatos: mes a mes	106
22.6	Contar imágenes por tile y mes	107
22.7	Intersectar tiles con una región de estudio	108
22.8	Visualizar cobertura mensual en un mapa	108

1 Python de Extremo a Extremo

Automatización, Análisis Geoespacial y Visión Artificial

Manual práctico con ejemplos reales de procesamiento de datos científicos: desde la lectura de archivos hasta la generación automática de informes Word, el análisis espectral de series temporales, la digitalización de cartografía con OCR y el manejo de datos geoespaciales.

1.1 Contenidos

- **Parte I** — Entorno Spyder, sintaxis y fundamentos del lenguaje
- **Parte II** — Manejo de datos con NumPy, Pandas y lectura de archivos
- **Parte III** — Visualización con Matplotlib, rosas de viento y figuras para informes
- **Parte IV** — Análisis de señales: estadísticas circulares, FFT y filtros
- **Parte V** — Automatización de informes Word con python-docx
- **Parte VI** — Datos geoespaciales con Rasterio y GeoPandas
- **Parte VII** — Visión artificial: OCR de cartas batimétricas con OpenCV y Tesseract
- **Parte VIII** — Modelos numéricos oceánicos: outputs NetCDF de CROCO con xarray
- **Parte IX** — Datos satelitales: Sentinel-2 vía API STAC de Copernicus y análisis de tiles MGRS

1.2 Requisitos

```
pip install numpy pandas matplotlib scipy openpyxl python-docx windrose rasterio  
↪ geopandas pyproj contextily opencv-python pytesseract pillow xarray netcdf4  
↪ cartopy pystac-client shapely
```

1.3 Cómo usar este manual

Cada capítulo incluye explicaciones y fragmentos de código aplicados a problemas reales de procesamiento de datos.

2 Entorno Spyder

Spyder es el entorno de desarrollo recomendado para análisis científico en Python. A diferencia de otros editores, está diseñado específicamente para trabajar con datos: tiene un explorador de variables integrado, una consola interactiva y permite ejecutar código por secciones.

2.1 Instalación

La forma más sencilla es instalar **Anaconda**, que incluye Python, Spyder y las librerías científicas principales:

<https://www.anaconda.com/download>

2.2 La interfaz de Spyder

Spyder tiene tres paneles principales:

Editor (tu código)	Variable Explorer (variables activas)
	Consola IPython (resultados)

- **Editor:** donde escribes y guardas tu script .py
- **Consola IPython:** donde se ejecuta el código y se muestran resultados
- **Variable Explorer:** muestra todas las variables activas, sus tipos y valores — muy útil para inspeccionar DataFrames y arrays

2.3 Ejecutar código

Acción	Atajo
Ejecutar el script completo	F5
Ejecutar la línea actual	F9
Ejecutar una selección	Seleccionar + F9
Ejecutar una celda	Ctrl + Enter
Ejecutar celda y avanzar	Shift + Enter

2.4 Atajos de edición esenciales

Acción	Atajo
Comentar / descomentar selección	Ctrl + 1
Insertar separador de celda # %%	Ctrl + 2
Duplicar línea	Ctrl + D

Acción	Atajo
Mover línea arriba / abajo	Alt + ↑ / ↓
Buscar en el archivo	Ctrl + F
Ir a definición de función	Ctrl + G

Ctrl + 1 es especialmente útil para desactivar temporalmente un bloque de código sin borrarlo. Ctrl + 2 inserta un `# %%` en la posición del cursor, creando una nueva celda ejecutable en ese punto.

2.5 Celdas de código

Las celdas permiten dividir el script en bloques ejecutables de forma independiente, similar a un notebook pero dentro de un archivo `.py` normal.

Se definen con `# %%`:

```
# %% Cargar datos
import pandas as pd
df = pd.read_csv('corrientes.csv')

# %% Graficar
import matplotlib.pyplot as plt
plt.plot(df['velocidad'])
plt.show()
```

Cada bloque `# %%` se puede ejecutar por separado con Ctrl + Enter. Esto es muy útil para procesar datos paso a paso sin reejecutar todo el script.

2.6 Variable Explorer

El explorador de variables muestra en tiempo real:

- Nombre y tipo de cada variable
- Dimensiones de arrays y DataFrames
- Vista previa de los valores

Se puede hacer doble clic en un DataFrame para abrirlo en una tabla interactiva, o en un array para ver su contenido completo.

2.7 Consola IPython

La consola acepta comandos directos sin necesidad de estar en el editor:

```
# Ver las primeras filas de un DataFrame
df.head()

# Ver el tipo de una variable
type(df)
```



```
# Obtener ayuda de una función
help(pd.read_csv)
# o más rápido:
pd.read_csv?
```

2.8 Configuración recomendada

Algunas opciones útiles en **Tools** → **Preferences**:

- **Editor** → **mostrar números de línea**: facilita depuración
- **IPython console** → **Graphics** → **Backend: Inline**: los gráficos aparecen en la consola (recomendado para análisis)
- **IPython console** → **Graphics** → **Backend: Tkinter**: cada gráfico abre en ventana separada, liviana e interactiva (zoom, pan, guardar)
- **IPython console** → **Graphics** → **Backend: Qt5**: similar a Tkinter pero más pesado; en algunos equipos es lento o inestable

También se puede cambiar el backend por sesión desde la consola sin tocar las preferencias:

```
%matplotlib inline    # figuras en consola
%matplotlib tk         # ventana Tkinter interactiva
%matplotlib qt5        # ventana Qt5
```

2.8.1 Cuándo usar cada backend

Situación	Backend
Explorar datos, iterar rápido	Inline
Revisar figura con zoom o hacer clics sobre ella	Tkinter
Script automático que solo guarda PNG	<code>matplotlib.use('Agg')</code> antes de importar <code>pyplot</code>

► **Recomendación** — Usar Inline como predeterminado. Cambiar a Tkinter cuando se necesita interactividad (zoom, edición de puntos, inspector de coordenadas). Qt5 solo vale la pena si Tkinter falla o se necesitan widgets más complejos.

3 Sintaxis básica

Python es un lenguaje de tipado dinámico e indentado. No necesita declarar tipos de variables ni usar llaves {} para delimitar bloques — la estructura del código se define por la indentación.

3.1 Variables y tipos

Python detecta el tipo de una variable automáticamente al asignarla. No es necesario declararlo. Los tipos fundamentales son:

3.1.1 float — número decimal

Representa cualquier número con parte decimal. Internamente usa 64 bits (doble precisión), lo que da ~15 dígitos significativos de precisión.

```
velocidad = 3.5      # float
temperatura = -1.8    # float (puede ser negativo)
proporcion = 0.73    # float entre 0 y 1

type(velocidad)      # <class 'float'>
```

Se usa para mediciones físicas: velocidades, temperaturas, coordenadas, profundidades. Cualquier número que pueda tener decimales debe ser float.

□ **Precisión de float** — Los floats tienen un error de representación inherente. $0.1 + 0.2$ en Python da 0.30000000000000004 , no 0.3 . Esto rara vez afecta el análisis de datos, pero sí puede causar sorpresas en comparaciones exactas. Usar `round()` o `np.isclose()` en vez de `==` para comparar floats.

3.1.2 int — número entero

Número sin parte decimal. En Python 3 no tiene límite de tamaño.

```
n_muestras = 186     # int
profundidad = 7       # int (metros exactos)
indice      = 0       # int — los índices siempre son int

type(n_muestras)     # <class 'int'>
```

Se usa para contadores, índices, cantidades discretas (número de archivos, de celdas, de meses).

```
# La división entre ints en Python 3 siempre da float
7 / 2      # 3.5    (float)
7 // 2     # 3      (int — división entera)
7 % 2      # 1      (int — resto)
```

3.1.3 str — texto

Secuencia de caracteres. Se define con comillas simples o dobles (equivalentes).

```
nombre_proyecto = "Los Vilos Oct 2025"
unidad          = 'm/s'
ruta            = r'C:\Users\Tomas\datos.csv'  # r"..." ignora las barras invertidas
```

3.1.4 bool — booleano

Solo dos valores posibles: True o False. Es un caso especial de int (True == 1, False == 0).

```
datos_validos = True
es_negativo   = velocidad < 0  # bool resultado de una comparación

# Se usa en condiciones
if datos_validos:
    procesar(df)
```

3.1.5 None — ausencia de valor

Representa "sin valor". Equivalente a NULL en otras lenguas.

```
resultado = None  # aún no calculado

# Verificar si algo es None
if resultado is None:
    print("Aún no hay resultado")
```

3.1.6 Resumen y conversión entre tipos

```
# Verificar tipo
type(3.5)    # <class 'float'>
type(23)     # <class 'int'>
type("texto") # <class 'str'>
type(True)   # <class 'bool'>

# Convertir
int(3.9)     # 3      - trunca, no redondea
float(23)    # 23.0
str(186)     # '186'
int("23")    # 23     - solo si el string es un número válido
bool(0)      # False  - 0 es falso, cualquier otro número es True
bool("")     # False  - string vacío es falso
```

3.1.7 ¿Cuándo importa el tipo?

```
# Concatenar string con número da error
nombre = "Profundidad: " + 7          # TypeError
nombre = "Profundidad: " + str(7)     # OK: "Profundidad: 7"
nombre = f"Profundidad: {7}"          # OK con f-string (convierte automático)

# Operaciones entre int y float dan float
3 + 1.5    # 4.5 (float)
7 * 2.0    # 14.0 (float)
```

3.2 Strings (texto)

```
empresa = "Compas Marine"
centro = "Los Vilos"

# Concatenación
titulo = empresa + " - " + centro

# f-strings (la forma moderna y más legible)
titulo = f"{empresa} - {centro}"

# Formateo con decimales
promedio = 3.93
texto = f"Velocidad promedio: {promedio:.2f} m/s"
# → "Velocidad promedio: 3.93 m/s"

# Métodos útiles
"Los Vilos".upper()      # 'LOS VILOS'
" texto ".strip()        # 'texto'
"a,b,c".split(",")       # ['a', 'b', 'c']
"corrientes".replace("e", "a") # 'corriantes'
```

3.3 Listas

Las listas almacenan secuencias de elementos de cualquier tipo:

```
profundidades = [3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23]
meses = ["sep", "oct", "nov", "dic", "ene", "feb", "mar"]

# Acceso por índice (empieza en 0)
profundidades[0]    # 3
profundidades[-1]   # 23 (último)
profundidades[2:5]  # [7, 9, 11] (slice)

# Operaciones
```

```
len(profundidades)      # 11
profundidades.append(25) # agrega al final
profundidades.sort()    # ordena en lugar
sum(profundidades)      # suma
```

3.4 Diccionarios

Los diccionarios almacenan pares clave-valor. Son muy usados para configuración:

```
config = {
    "empresa": "Compas Marine",
    "centro": "Los Vilos",
    "lat": -31.9,
    "lon": -71.5,
    "prof_max": 23
}

# Acceso
config["empresa"]      # "Compas Marine"
config.get("lat", None) # -31.9 (con valor por defecto si no existe)

# Modificar
config["prof_max"] = 25

# Iterar
for clave, valor in config.items():
    print(f"{clave}: {valor}")
```

3.5 Indentación

Python usa la indentación (4 espacios) para delimitar bloques. No hay llaves ni end:

```
# Correcto
if velocidad > 0.5:
    print("Velocidad alta")
    print("Revisar datos")

# Error – la indentación inconsistente produce IndentationError
if velocidad > 0.5:
print("Velocidad alta") # ← falta indentación
```

3.6 Comentarios

```
# Comentario de una línea

velocidad_max = 0.6 # m/s – comentario al final de línea
```

```
"""
Comentario de
múltiples líneas
(también se usa como docstring de funciones)
"""
```

3.7 Operadores

```
# Aritméticos
3 + 2      # 5
10 / 3     # 3.333...
10 // 3    # 3 (división entera)
10 % 3     # 1 (módulo / resto)
2 ** 3     # 8 (potencia)

# Comparación
5 > 3      # True
5 == 5     # True (igualdad, no asignación)
5 != 4     # True

# Lógicos
True and False # False
True or False  # True
not True       # False

# Útil con pandas: operadores por elemento
velocidad > 0.1      # Series de booleanos
(vel > 0.1) & (dir < 90) # AND elemento a elemento
```

3.8 Conversión de tipos

```
int("23")      # 23
float("3.5")    # 3.5
str(186)        # "186"
list((1, 2, 3)) # [1, 2, 3]
```

❏ **Error frecuente** — En Python 3, dividir dos enteros siempre devuelve float: $7 / 2 = 3.5$. Para división entera usa `//`.

4 Control de flujo

El control de flujo determina qué código se ejecuta y cuándo. En procesamiento oceanográfico se usa constantemente: para filtrar datos, iterar sobre profundidades, manejar errores de lectura, etc.

4.1 Condicionales: if / elif / else

```
velocidad = 0.35

if velocidad >= 0.5:
    categoria = "alta"
elif velocidad >= 0.2:
    categoria = "moderada"
else:
    categoria = "baja"

print(f"Velocidad {categoria}: {velocidad} m/s")
```

4.1.1 Condicional en una línea (ternario)

```
etiqueta = "válido" if velocidad > 0 else "calma"
```

4.2 Bucles: for

El bucle for itera sobre cualquier secuencia: listas, rangos, columnas de un DataFrame, archivos, etc.

```
profundidades = [3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23]

for prof in profundidades:
    print(f"Procesando capa a {prof} m")
```

4.2.1 range()

```
# range(inicio, fin, paso) – fin no se incluye
for i in range(0, 12):          # 0 a 11
    print(i)

for i in range(0, 24, 2):       # 0, 2, 4, ..., 22
    print(i)
```

4.2.2 enumerate() — índice + valor

```
meses = ["sep", "oct", "nov", "dic", "ene", "feb", "mar"]

for i, mes in enumerate(meses):
    print(f"Mes {i+1}: {mes}")
```

4.2.3 Iterar sobre un diccionario

```
stats = {"media": 3.93, "maxima": 18.2, "std": 2.8}

for nombre, valor in stats.items():
    print(f"{nombre}: {valor:.2f}")
```

4.3 Bucles: while

```
intentos = 0
while intentos < 3:
    print(f"Intento {intentos + 1}")
    intentos += 1
```

4.4 break y continue

```
for prof in profundidades:
    if prof > 15:
        break          # sale del bucle al llegar a 17 m

for prof in profundidades:
    if prof == 9:
        continue       # salta esta iteración, continúa con la siguiente
    print(prof)
```

4.5 List comprehensions

Una forma compacta de construir listas a partir de otra secuencia. Muy usadas en el procesamiento de datos para transformar o filtrar colecciones:

```
profundidades = [3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23]

# Sin comprehension
dobles = []
for p in profundidades:
    dobles.append(p * 2)
```



```
# Con comprehension (equivalente, más conciso)
dobles = [p * 2 for p in profundidades]

# Con filtro
superficiales = [p for p in profundidades if p <= 7]
# → [3, 5, 7]
```

4.5.1 Ejemplo real del pipeline

```
# Buscar todos los archivos Excel de corrientes en un directorio
import os
archivos = [f for f in os.listdir(carpeta) if f.endswith('.xlsx')]
```

4.6 Manejo de errores: try / except

Fundamental cuando se leen archivos o datos que pueden estar incompletos o corruptos:

```
try:
    df = pd.read_csv('corrientes.csv')
except FileNotFoundError:
    print("Archivo no encontrado")
except Exception as e:
    print(f"Error inesperado: {e}")
```

4.6.1 finally — código que siempre se ejecuta

```
try:
    archivo = open('datos.txt')
    datos = archivo.read()
except FileNotFoundError:
    print("No se encontró el archivo")
finally:
    print("Proceso terminado") # se ejecuta siempre
```

4.6.2 Ejemplo real del pipeline

En el código de automatización de informes, el try/except se usa para detectar si un archivo de figuras existe antes de intentar insertarlo en el Word:

```
try:
    doc.paragraphs[idx].runs[0].add_picture(ruta_figura, width=ancho)
except Exception as e:
    print(f" ! No se pudo insertar figura: {e}")
```

4.7 Combinando estructuras

Donde el control de flujo se vuelve útil de verdad es cuando se combinan varias capas. Las estructuras individuales son simples; la habilidad está en encadenarlas para resolver problemas reales.

4.7.1 for + if: filtrar mientras se itera

```
profundidades = [3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23]
velocidades   = [0.08, 0.09, 0.6, 0.07, 0.08, 0.09, 0.10, 0.09, 0.08, 0.07, 0.06]

# Recorrer dos listas a la vez con zip()
for prof, vel in zip(profundidades, velocidades):
    if vel > 0.5:
        print(f"Alerta en {prof} m: velocidad = {vel:.2f} m/s")
```

zip() empareja dos listas elemento a elemento: en cada vuelta del for, prof y vel corresponden al mismo índice.

4.7.2 for + if + acumulador: encontrar el máximo con contexto

```
maxima = 0
prof_maxima = None

for prof, vel in zip(profundidades, velocidades):
    if vel > maxima:
        maxima = vel
        prof_maxima = prof

print(f"Velocidad máxima: {maxima} m/s a {prof_maxima} m de profundidad")
# → Velocidad máxima: 0.6 m/s a 7 m de profundidad
```

El acumulador (maxima, prof_maxima) guarda el resultado parcial mientras el loop avanza. Al terminar, tiene la respuesta final.

4.7.3 for + try/except: procesar lotes sin que un error detenga todo

```
import pandas as pd

archivos = ['oct2024.csv', 'nov2024.csv', 'dic_corrupto.csv', 'ene2025.csv']
dataframes = []

for nombre in archivos:
    try:
        df = pd.read_csv(nombre)
        dataframes.append(df)
        print(f"OK: {nombre} ({len(df)} filas)")
```

```

except FileNotFoundError:
    print(f" ! No encontrado: {nombre}")
except Exception as e:
    print(f" ! Error en {nombre}: {e}")

```

```
df_total = pd.concat(dataframes)
```

Sin el try/except, el primer archivo problemático detendría el script y perderías los datos buenos que venían después. Con él, el loop sigue y al final tienes todo lo que se pudo leer.

4.7.4 for anidado: recorrer filas y columnas

```

profundidades = [5, 10, 20]
meses = ['oct', 'nov', 'dic']

for mes in meses:
    for prof in profundidades:
        # aquí iría la lógica para cada combinación mes × profundidad
        print(f"Procesando {mes} a {prof} m")

```

Útil cuando se necesita hacer algo para cada combinación de dos listas. Ojo: si cada lista tiene N elementos, el loop interno se ejecuta N^2 veces. Con listas grandes, conviene pensar si hay una forma vectorizada (NumPy/Pandas) que sea más eficiente.

4.7.5 Comprehension con condición vs for + if

Cuando el objetivo es construir una lista filtrada, la comprehension es más clara:

```

# for + if (más verboso)
superficiales = []
for p in profundidades:
    if p <= 7:
        superficiales.append(p)

# comprehension (equivalente, más directo)
superficiales = [p for p in profundidades if p <= 7]

```

La comprehension se lee de corrido: "lista de p, para cada p en profundidades, si $p \leq 7$ ". Úsala cuando la lógica cabe en una línea. Si hay condiciones anidadas o el cuerpo del loop hace varias cosas, el for explícito es más fácil de leer y modificar.

4.7.6 Patrón completo: lectura + filtrado + reporte

```

import os
import pandas as pd

```

```

carpeta = 'datos/'
resultados = []

for archivo in os.listdir(carpeta):
    if not archivo.endswith('.csv'):
        continue # saltar archivos que no son CSV

    try:
        df = pd.read_csv(os.path.join(carpeta, archivo))
        vel_max = df['velocidad'].max()
        resultados.append({'archivo': archivo, 'vel_max': vel_max})

    except Exception as e:
        print(f" ! {archivo}: {e}")

# Ordenar por velocidad máxima
resultados.sort(key=lambda x: x['vel_max'], reverse=True)

for r in resultados:
    print(f"{r['archivo']:30s} vel_max = {r['vel_max']:.2f} m/s")

```

Este patrón — iterar sobre archivos, saltar los irrelevantes, capturar errores, acumular resultados, ordenar y reportar — aparece constantemente en scripts de análisis real.

5 Funciones y módulos

5.1 Funciones

5.1.1 ¿Por qué hacer una función?

Cuando un mismo bloque de código aparece más de una vez — aunque sea con pequeñas variaciones — conviene convertirlo en función. Así se escribe una sola vez, se prueba una sola vez, y si hay que corregirlo se cambia en un solo lugar.

```
# Sin función: repetir la misma lógica para cada mes
vel_oct = datos_oct['velocidad']
media_oct = vel_oct.mean()
std_oct = vel_oct.std()
max_oct = vel_oct.max()
print(f"Oct - media={media_oct:.2f} std={std_oct:.2f} max={max_oct:.2f}")

vel_nov = datos_nov['velocidad']
media_nov = vel_nov.mean()
std_nov = vel_nov.std()
max_nov = vel_nov.max()
print(f"Nov - media={media_nov:.2f} std={std_nov:.2f} max={max_nov:.2f}")

# Con función: escribir la lógica una vez
def reportar_estadisticas(df, nombre):
    vel = df['velocidad']
    print(f"{nombre} - media={vel.mean():.2f} std={vel.std():.2f}
    ↪ max={vel.max():.2f}")

reportar_estadisticas(datos_oct, 'Oct')
reportar_estadisticas(datos_nov, 'Nov')
reportar_estadisticas(datos_dic, 'Dic')
```

La función no solo ahorra líneas — hace el código más fácil de entender porque el nombre `reportar_estadisticas` describe exactamente qué hace.

Una función agrupa código reutilizable bajo un nombre. En un pipeline de procesamiento de datos casi toda la lógica está organizada en funciones: una para leer datos, otra para filtrar, otra para graficar, etc.

```
def calcular_media_vectorial(velocidades, direcciones):
    """Calcula la dirección y velocidad resultante del vector medio."""
    import numpy as np
    u = velocidades * np.sin(np.radians(direcciones))
    v = velocidades * np.cos(np.radians(direcciones))
    u_media = np.mean(u)
    v_media = np.mean(v)
    vel_media = np.sqrt(u_media**2 + v_media**2)
    dir_media = np.degrees(np.arctan2(u_media, v_media)) % 360
```

```
return vel_media, dir_media
```

5.1.2 Sintaxis básica

```
def nombre_funcion(parametro1, parametro2):  
    # cuerpo de la función  
    resultado = parametro1 + parametro2  
    return resultado  
  
# Llamar la función  
total = nombre_funcion(3, 5)    # total = 8
```

5.1.3 Parámetros por defecto

```
def leer_corrientes(ruta, sep=';', skiprows=0, encoding='utf-8'):  
    import pandas as pd  
    return pd.read_csv(ruta, sep=sep, skiprows=skiprows, encoding=encoding)  
  
# Uso mínimo (usa los valores por defecto)  
df = leer_corrientes('datos.csv')  
  
# Sobreescribir un parámetro específico  
df = leer_corrientes('datos.csv', sep=',', skiprows=2)
```

5.1.4 Múltiples valores de retorno

Python puede retornar múltiples valores como una tupla:

```
def estadisticas(datos):  
    import numpy as np  
    return np.mean(datos), np.max(datos), np.std(datos)  
  
media, maximo, desviacion = estadisticas(velocidades)
```

5.1.5 Argumentos con nombre (kwargs)

```
def guardar_figura(fig, nombre, dpi=150, formato='png'):  
    ruta = f"figuras/{nombre}.{formato}"  
    fig.savefig(ruta, dpi=dpi, bbox_inches='tight')  
    print(f"Figura guardada: {ruta}")  
  
# Se pueden pasar en cualquier orden si se nombran  
guardar_figura(fig, "rosa_corrientes", formato='pdf', dpi=300)
```

5.2 Módulos e imports

Un módulo es un archivo .py que contiene funciones, clases y variables. Las librerías como NumPy, Pandas y Matplotlib son colecciones de módulos.

5.2.1 Formas de importar

```
# Importar la librería completa
import numpy

# Con alias (convención estándar)
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Importar solo lo que se necesita
from datetime import datetime, timezone
from pathlib import Path
```

5.2.2 Importar funciones propias

Si tienes tus funciones en otro archivo, por ejemplo utils.py:

```
# utils.py
def convertir_uv(velocidad, direccion):
    import numpy as np
    u = velocidad * np.sin(np.radians(direccion))
    v = velocidad * np.cos(np.radians(direccion))
    return u, v
```

Se importa así desde otro script:

```
from utils import convertir_uv

u, v = convertir_uv(0.35, 45)
```

5.2.3 sys.path — importar desde otra carpeta

Cuando el archivo que necesitas está en otro directorio, hay que agregar esa ruta al path de Python:

```
import sys
sys.path.insert(0, '/ruta/a/mi/libreria')

from mi_modulo import mi_funcion
```

Esto se usa constantemente en el pipeline de procesamiento, por ejemplo en run_pipeline.py para cargar los módulos de cada instrumento.

5.2.4 importlib — carga dinámica

Cuando la ruta del módulo se conoce solo en tiempo de ejecución (por ejemplo, depende de qué proyecto se está procesando), se usa `importlib`:

```
import importlib.util

def cargar_modulo(ruta_archivo):
    spec = importlib.util.spec_from_file_location("modulo", ruta_archivo)
    modulo = importlib.util.module_from_spec(spec)
    spec.loader.exec_module(modulo)
    return modulo

# Cargar el script de notas del analista
notas = cargar_modulo('/proyectos/LosVilos/notas_informe.py')
parrafo_viento = notas.parrafo_viento
```

5.3 Organizar código en módulos

A medida que los scripts crecen, conviene separar el código en archivos temáticos. Un ejemplo de estructura para un proyecto de análisis oceanográfico:

```
ocean_data_analysis/
├─ __init__.py
├─ read_data.py           ← funciones de lectura
├─ preprocessing.py      ← filtros y correcciones
├─ wave_processing.py    ← análisis de oleaje
├─ wind_figures.py       ← figuras de viento
├─ current_z_figures.py  ← figuras de corrientes
└─ extreme_events.py     ← análisis de eventos extremos
```

El archivo `__init__.py` (puede estar vacío) le indica a Python que esa carpeta es un paquete importable.

5.4 Scope (alcance de variables)

Las variables definidas dentro de una función son locales — no existen fuera de ella:

```
def procesar():
    resultado = 42      # variable local
    return resultado

procesar()
print(resultado)       # NameError: resultado no existe aquí
```

Para compartir datos entre funciones, lo correcto es usar el valor de retorno, no variables globales.

► **Buena práctica** — Escribe funciones pequeñas que hagan una sola cosa. Es más

fácil probarlas, reutilizarlas y entenderlas. Si una función supera las 50 líneas, probablemente conviene dividirla.

6 NumPy

NumPy es la librería fundamental para cálculo numérico en Python. Su estructura central es el **array**: un arreglo multidimensional de valores del mismo tipo, mucho más eficiente que una lista de Python para operaciones matemáticas.

```
import numpy as np
```

6.1 Arrays vs listas de Python

La pregunta más común al empezar con NumPy es: ¿cuándo usar un array y cuándo una lista?

	Lista de Python	Array de NumPy
Tipos de elementos	Mixtos ([1, "texto", True])	Todos del mismo tipo
Operaciones matemáticas	Requieren un loop	Directas sobre todo el array
Velocidad	Lenta para cálculos	10-100× más rápida
Uso típico	Colecciones generales, texto	Series numéricas, matrices

```
# Lista – la operación no funciona como se espera
velocidades_lista = [0.08, 0.09, 0.6, 0.07]
velocidades_lista * 1.944 # repite la lista, no multiplica cada elemento

# Array – la operación se aplica a cada elemento
velocidades = np.array([0.08, 0.09, 0.6, 0.07])
velocidades * 1.944 # [0.156, 0.175, 1.166, 0.136] – correcto
```

Regla práctica: si vas a hacer cálculos (sumas, medias, trigonometría), usa arrays. Si solo necesitas guardar una colección de cosas para iterar sobre ellas, una lista está bien.

6.2 Arrays

```
# Desde una lista
velocidades = np.array([0.08, 0.09, 0.6, 0.07, 0.08, 0.09, 0.10])

# Array de ceros o unos
np.zeros(12) # [0. 0. 0. ... 0.]
np.ones((3, 4)) # matriz 3x4 de unos

# Secuencias
np.arange(0, 24, 2) # [0, 2, 4, ..., 22]
np.linspace(0, 1, 50) # 50 puntos equiespaciados entre 0 y 1
```

6.2.1 Arrays 2D — matrices

En corrientes se trabaja frecuentemente con matrices de (tiempo × profundidad):

```
# Matriz de velocidades: 5 ensembles × 11 profundidades
datos = np.array([
    [0.08, 0.09, 0.6, 0.07, 0.08, 0.09, 0.10, 0.09, 0.08, 0.07, 0.06],
    [0.07, 0.08, 0.55, 0.06, 0.07, 0.08, 0.09, 0.08, 0.07, 0.06, 0.05],
    # ...
])

datos.shape    # (5, 11) — filas × columnas
datos.ndim     # 2
datos.size     # 55 — total de elementos
```

6.3 Operaciones vectorizadas y broadcasting

La ventaja de NumPy es que las operaciones se aplican a todo el array sin necesidad de un loop. A esto se le llama **vectorización**:

```
vel = np.array([0.08, 0.09, 0.6, 0.07])

# Operaciones elemento a elemento
vel * 1.944      # convertir m/s a nudos
vel ** 2         # cuadrado de cada elemento
np.sqrt(vel)     # raíz cuadrada
np.log(vel)      # logaritmo natural

# Comparación — devuelve array de booleanos
vel > 0.5        # [False, False, True, False]
```

Broadcasting es la regla que permite operar un array con un escalar (o con arrays de distinta forma compatible). NumPy “expande” el escalar para que coincida con el tamaño del array:

```
vel = np.array([0.08, 0.09, 0.6, 0.07])

# En vez de hacer un loop para convertir cada elemento:
# for i in range(len(vel)):
#     vel[i] = vel[i] * 1.944

# NumPy lo hace solo — aplica el *1.944 a cada elemento:
vel * 1.944      # [0.156, 0.175, 1.166, 0.136]

# Sumar dos arrays del mismo tamaño — suma elemento a elemento:
u = np.array([0.1, 0.2, 0.3])
v = np.array([0.4, 0.5, 0.6])
magnitud = np.sqrt(u**2 + v**2) # calcula raíz de (u2+v2) para cada par
```

6.3.1 Conversión velocidad/dirección ↔ componentes U, V

Esta operación es fundamental en oceanografía y aparece en múltiples scripts del pipeline:

```
def uv_desde_vel_dir(velocidad, direccion_grad):
    """Convierte (velocidad, dirección) a componentes (U, V)."""
    dir_rad = np.radians(direccion_grad)
    u = velocidad * np.sin(dir_rad) # componente Este
    v = velocidad * np.cos(dir_rad) # componente Norte
    return u, v

def vel_dir_desde_uv(u, v):
    """Convierte (U, V) a (velocidad, dirección)."""
    velocidad = np.sqrt(u**2 + v**2)
    direccion = np.degrees(np.arctan2(u, v)) % 360
    return velocidad, direccion
```

6.4 Indexación y slicing

```
prof = np.array([3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23])

prof[0]      # 3 - primer elemento
prof[-1]     # 23 - último
prof[2:5]    # [7, 9, 11]
prof[::2]    # [3, 7, 11, 15, 19, 23] - cada dos

# En 2D: [fila, columna]
datos[0, :]  # primera fila completa (ensemble 0, todas las profundidades)
datos[:, 2]  # columna 2 completa (todos los ensembles, profundidad 7 m)
datos[1:3, 3:6] # submatriz
```

6.4.1 Indexación booleana — filtrado

```
vel = np.array([0.08, 0.09, 0.6, 0.07, 0.55, 0.09])

# Seleccionar solo los valores > 0.5
vel[vel > 0.5]      # [0.6, 0.55]

# Reemplazar valores fuera de rango con NaN
vel[vel > 0.5] = np.nan
```

6.5 Estadísticas

```
vel = np.array([0.08, 0.09, 0.60, 0.07, 0.08])
```

```

np.mean(vel)          # media
np.median(vel)        # mediana
np.std(vel)           # desviación estándar
np.max(vel)           # máximo
np.min(vel)           # mínimo
np.percentile(vel, 95) # percentil 95

np.argmax(vel)        # índice del máximo → 2

```

6.5.1 Funciones que ignoran NaN

Cuando los datos tienen valores faltantes (NaN), usar las versiones nan*:

```

np.nanmean(vel)
np.nanmax(vel)
np.nanstd(vel)
np.nanpercentile(vel, 95)

```

6.5.2 Estadísticas por eje en matrices

```

datos.mean(axis=0) # media por profundidad (a lo largo del tiempo)
datos.mean(axis=1) # media por ensemble (a lo largo de profundidades)
datos.max(axis=0)  # máximo por profundidad

```

6.6 Funciones trigonométricas

NumPy trabaja en radianes. Para datos de dirección oceánica (en grados):

```

np.radians(180)    #  $\pi$ 
np.degrees(np.pi)  # 180.0

np.sin(np.radians(90)) # 1.0
np.cos(np.radians(0))  # 1.0

# arctan2 – dirección del vector (U, V)
u, v = 0.5, 0.5
direccion = np.degrees(np.arctan2(u, v)) % 360 # 45.0°

```

6.7 NaN — valores faltantes

```

np.nan                # valor especial "Not a Number"
np.isnan(vel)         # array booleano: True donde hay NaN
np.isnan(vel).sum()   # cantidad de NaN
~np.isnan(vel)        # máscara de datos válidos

```

```
# Contar datos válidos  
datos_validos = vel[~np.isnan(vel)]
```

6.8 Operaciones útiles

```
# Diferencia entre elementos consecutivos  
np.diff(np.array([1, 3, 6, 10]))    # [2, 3, 4]  
  
# Concatenar arrays  
a = np.array([1, 2, 3])  
b = np.array([4, 5, 6])  
np.concatenate([a, b])              # [1, 2, 3, 4, 5, 6]  
  
# Apilar matrices verticalmente  
np.vstack([datos[:2, :], datos[3:, :]])  
  
# Ordenar  
np.sort(vel)                        # copia ordenada  
vel.argsort()                       # índices que ordenarían el array  
  
# Redondear  
np.round(3.14159, 2)                # 3.14
```

► **NumPy vs listas de Python** — Para operaciones matemáticas sobre grandes conjuntos de datos, NumPy es entre 10 y 100 veces más rápido que un loop sobre una lista Python. En series temporales de 6 meses con datos cada 10 minutos (~26.000 registros), esa diferencia es significativa.

7 Pandas

Pandas es la librería principal para manejo de datos tabulares. Su estructura central es el **DataFrame**: una tabla con filas y columnas etiquetadas, similar a una hoja de Excel pero operable desde código.

En el procesamiento de datos oceanográficos, los datos de corrientes, viento y oleaje se manejan como DataFrames de Pandas.

```
import pandas as pd
```

7.1 Series y DataFrames

Una **Series** es una columna con índice. Un **DataFrame** es una tabla de Series con el mismo índice.

```
# Series
velocidad = pd.Series([0.08, 0.09, 0.6, 0.07], name='velocidad')

# DataFrame desde diccionario
df = pd.DataFrame({
    'velocidad': [0.08, 0.09, 0.60, 0.07],
    'direccion': [ 45,   90,  352,  180],
    'profundidad': [ 3,   3,   7,   3],
})
```

7.2 Explorar un DataFrame

```
df.head()           # primeras 5 filas
df.tail(10)         # últimas 10 filas
df.shape            # (filas, columnas)
df.columns          # nombres de columnas
df.dtypes           # tipo de cada columna
df.describe()       # estadísticas básicas
df.info()           # resumen general: tipos, NaN, memoria
```

7.3 Acceder a datos

```
# Columna por nombre
df['velocidad']
df[['velocidad', 'direccion']] # varias columnas
```

7.3.1 loc vs iloc — etiqueta vs posición

Esta es la distinción que más confunde al principio. La diferencia es simple:

- **iloc** — accede por **posición numérica**, como los índices de una lista (0, 1, 2...)

- **loc** — accede por **etiqueta del índice**, que puede ser un número, una fecha, un string

```
# Si el índice del DataFrame es 0, 1, 2... ambos parecen iguales
df.iloc[0]      # primera fila (por posición)
df.loc[0]       # fila con etiqueta 0 (por etiqueta)

# La diferencia importa cuando el índice es una fecha
df = df.set_index('tiempo') # índice es ahora DatetimeIndex

df.iloc[0]      # primera fila del DataFrame
df.loc['2025-10-01'] # fila con esa fecha exacta
df.loc['2025-10-01':'2025-10-31'] # rango de fechas – solo funciona con loc
```

Regla práctica: si trabajas con series temporales (índice de fechas), usa `loc`. Si solo necesitas “las primeras N filas” o “la fila en la posición X”, usa `iloc`.

```
# Combinando filas y columnas
df.iloc[0:5, 1:3]      # filas 0-4, columnas 1-2 (posición)
df.loc['2025-10', ['velocidad', 'dir']] # octubre, columnas por nombre
```

7.4 Filtrado

```
# Condición simple
df[df['velocidad'] > 0.5]

# Múltiples condiciones
df[(df['velocidad'] > 0.1) & (df['profundidad'] == 3)]
df[(df['direccion'] < 45) | (df['direccion'] > 315)]

# isin – valores en una lista
df[df['profundidad'].isin([3, 7, 15])]

# notna / isna
df[df['velocidad'].notna()] # excluir NaN
df[df['velocidad'].isna()]  # solo NaN
```

7.5 Series temporales

En oceanografía, el índice del DataFrame suele ser un `DatetimeIndex`. Esto permite filtrar y agrupar por tiempo de forma muy eficiente.

```
# Crear índice temporal desde una columna
df['tiempo'] = pd.to_datetime(df['tiempo'])
df = df.set_index('tiempo')

# Filtrar por rango de fechas
df['2025-10':'2026-03']
```



```
df.loc['2025-10-01':'2026-03-30']

# Resamplear: promedios horarios, diarios, mensuales
df.resample('1h').mean()    # promedio cada hora
df.resample('1D').max()    # máximo diario
df.resample('1ME').mean()  # promedio mensual
```

7.5.1 Timezone

Los datos del ADCP y la boya están en UTC. Para convertir a hora local (UTC-3):

```
from datetime import timezone, timedelta

df.index = df.index.tz_localize('UTC')
df.index = df.index.tz_convert('America/Santiago')
```

7.6 Operaciones por columna

```
# Crear nuevas columnas
df['vel_nudos'] = df['velocidad'] * 1.944

# Operaciones sobre columnas existentes
df['u'] = df['velocidad'] * np.sin(np.radians(df['direccion']))
df['v'] = df['velocidad'] * np.cos(np.radians(df['direccion']))

# Reemplazar valores
df['velocidad'] = df['velocidad'].replace(-9999, np.nan)

# Aplicar función personalizada
def clasificar_beaufort(vel):
    if vel < 0.3:    return "calma"
    elif vel < 1.5:  return "ventolina"
    elif vel < 3.3:  return "brisa leve"
    else:           return "brisa moderada o más"

df['beaufort'] = df['velocidad'].apply(clasificar_beaufort)
```

7.7 Estadísticas

```
df['velocidad'].mean()
df['velocidad'].max()
df['velocidad'].std()
df['velocidad'].quantile(0.95)    # percentil 95

# Por columna
```

```
df.mean()
df.describe()

# Contar valores no nulos
df['velocidad'].count()
df['velocidad'].isna().sum()    # cantidad de NaN
```

7.8 groupby — estadísticas por categoría

groupby divide el DataFrame en grupos según el valor de una columna, calcula algo dentro de cada grupo, y devuelve los resultados combinados. Es el equivalente en código de “agrupar por X en una tabla pivot de Excel”.

DataFrame original	Después de groupby('profundidad')
profundidad velocidad	profundidad velocidad_media
3 0.08	3 0.085
3 0.09	7 0.335
7 0.60	← promedio dentro de cada grupo
7 0.07	

```
# Estadísticas por profundidad
df.groupby('profundidad')['velocidad'].mean()
df.groupby('profundidad')['velocidad'].agg(['mean', 'max', 'std'])

# Estadísticas por mes
df.groupby(df.index.month)['velocidad'].mean()

# Por hora del día (patrón diurno)
df.groupby(df.index.hour)['velocidad'].mean()
```

7.8.1 Ejemplo real: patrón diurno del viento

```
patron_diurno = df.groupby(df.index.hour)['velocidad'].mean()
patron_diurno.index.name = 'hora'
```

7.9 pivot_table — tabla de frecuencias

Las tablas de incidencia (velocidad × dirección) del informe se generan con pivot_table:

```
# Tabla de frecuencia: velocidad × dirección
tabla = pd.pivot_table(
    df,
    values='velocidad',
    index='intervalo_vel',
    columns='octante',
```

```

    aggfunc='count',
    fill_value=0
)

# Normalizar a porcentaje
tabla_pct = tabla / tabla.values.sum() * 100

```

7.10 merge y concat — combinar DataFrames

```

# Concatenar DataFrames con la misma estructura (unir registros)
df_total = pd.concat([df_septiembre, df_octubre, df_noviembre])

# Merge por columna común (equivalente a JOIN de SQL)
df_merged = pd.merge(df_corrientes, df_oleaje, on='tiempo', how='inner')

```

7.11 Manejar NaN

```

df.dropna()                # eliminar filas con cualquier NaN
df.dropna(subset=['velocidad']) # solo si velocidad es NaN
df.fillna(0)               # rellenar con 0
df['velocidad'].interpolate() # interpolación lineal
df.ffmpeg()                # propagar último valor válido hacia adelante

```

7.12 Leer y guardar datos

```

# Leer
df = pd.read_csv('corrientes.csv', sep=';', parse_dates=['tiempo'])
df = pd.read_excel('corrientes.xlsx', sheet_name='VELOCIDAD')

# Guardar
df.to_csv('resultado.csv', index=False)
df.to_excel('resultado.xlsx', sheet_name='Datos', index=False)

```

► **Variable Explorer en Spyder** — Hacer doble clic en un DataFrame en el Variable Explorer de Spyder abre una vista de tabla interactiva donde se pueden ordenar columnas y buscar valores, sin escribir ningún código adicional.

8 Lectura de archivos

Un pipeline de datos científicos lee de múltiples fuentes y formatos: CSV de dataloggers, Excel de procesamiento, archivos .mat de MATLAB, y documentos Word para extracción de metadata.

8.1 Archivos de texto y CSV

```
import pandas as pd

# CSV estándar
df = pd.read_csv('viento.csv')

# Opciones comunes
df = pd.read_csv(
    'viento.csv',
    sep=';',
    decimal=',',
    skiprows=2,
    encoding='latin-1',
    parse_dates=['fecha'],
    index_col='fecha',
    na_values=['-9999', 'N/A', '']
    # separador de columna
    # decimal con coma (datos europeos)
    # saltar filas de encabezado
    # encoding para tildes
    # convertir columna a datetime
    # usar fecha como índice
    # valores a tratar como NaN
)
```

8.1.1 Detectar encoding

Si el archivo tiene tildes y aparecen caracteres extraños, probar:

```
for enc in ['utf-8', 'latin-1', 'cp1252']:
    try:
        df = pd.read_csv('archivo.csv', encoding=enc)
        print(f"Funciona con: {enc}")
        break
    except UnicodeDecodeError:
        continue
```

8.2 Archivos Excel

```
# Hoja por nombre
df = pd.read_excel('corrientes.xlsx', sheet_name='VELOCIDAD')

# Primera hoja
df = pd.read_excel('corrientes.xlsx', sheet_name=0)

# Leer todas las hojas
```

```

hojas = pd.read_excel('corrientes.xlsx', sheet_name=None)
# hojas es un dict: {'VELOCIDAD': df1, 'DIRECCION': df2, ...}

for nombre, df in hojas.items():
    print(f"Hoja '{nombre}': {df.shape}")

```

8.2.1 Leer varias hojas de un Excel con múltiples pestañas

Cuando el Excel tiene hojas con nombres conocidos, conviene leerlas en un diccionario y manejar el caso de que alguna falte:

```

hojas_requeridas = ['Datos', 'Estadísticas', 'Resumen']

datos = {}
for hoja in hojas_requeridas:
    try:
        datos[hoja] = pd.read_excel('procesamiento.xlsx', sheet_name=hoja)
    except Exception as e:
        print(f" ! No se encontró la hoja '{hoja}': {e}")

```

8.3 Archivos MATLAB (.mat)

Los datos del equipo de oleaje STORM2 (Nortek) se exportan en formato .mat. Se leen con `scipy.io`:

```

from scipy.io import loadmat

mat = loadmat('datos_storm2.mat')

# mat es un diccionario con las variables del workspace de MATLAB
print(mat.keys())

# Extraer variables
Hm0 = mat['Hm0'].flatten()      # flatten convierte (N,1) → (N,)
Tp  = mat['Tp'].flatten()
tiempo = mat['time'].flatten()

```

8.3.1 Convertir tiempo MATLAB a datetime de Python

MATLAB guarda el tiempo como número de días desde el 0-ene-0000. Para convertir a pandas:

```

import pandas as pd
import numpy as np

def matlab_datenum_a_datetime(datenum):
    return pd.to_datetime(datenum - 719529, unit='D', origin='unix')

```

```
timestamps = matlab_datenum_a_datetime(tiempo)
```

8.4 Archivos JSON

```
import json

# Leer
with open('config.json', 'r', encoding='utf-8') as f:
    config = json.load(f)

empresa = config['empresa']

# Guardar
with open('estado.json', 'w', encoding='utf-8') as f:
    json.dump(config, f, ensure_ascii=False, indent=2)
```

8.5 Archivos de texto plano

```
# Leer completo
with open('notas.txt', 'r', encoding='utf-8') as f:
    contenido = f.read()

# Leer línea por línea
with open('log.txt', 'r') as f:
    for linea in f:
        print(linea.strip())

# Escribir
with open('resultado.txt', 'w', encoding='utf-8') as f:
    f.write("Velocidad máxima: 0.6 m/s\n")
    f.write("Profundidad: 7 m\n")
```

8.6 Buscar archivos con glob y os

En el pipeline es frecuente buscar archivos por patrón sin saber el nombre exacto:

```
import glob
import os

# Todos los Excel en una carpeta
archivos = glob.glob('/ruta/carpeta/*.xlsx')

# Recursivo (busca en subcarpetas también)
archivos = glob.glob('/ruta/**/*.xlsx', recursive=True)
```

```

# Filtrar con condición
excels_corrientes = [
    f for f in glob.glob('/ruta/*.xlsx')
    if 'corriente' in f.lower()
]

# Listar archivos y carpetas
os.listdir('/ruta/carpeta')

# Verificar si existe
os.path.exists('/ruta/archivo.csv')

# Construir rutas de forma segura (funciona en Windows y Linux)
ruta = os.path.join('/ruta/base', 'subcarpeta', 'archivo.csv')

```

8.7 Documentos Word (.docx)

Python-docx permite leer texto desde documentos Word, útil para extraer metadata de informes anteriores:

```

from docx import Document

doc = Document('informe.docx')

# Leer todos los párrafos
for parrafo in doc.paragraphs:
    if parrafo.text.strip():
        print(parrafo.text)

# Leer tablas
for tabla in doc.tables:
    for fila in tabla.rows:
        celdas = [celda.text for celda in fila.cells]
        print(celdas)

```

8.7.1 Leer .docx sin python-docx (XML directo)

Para extraer texto con más control, el .docx es en realidad un archivo ZIP con XML adentro:

```

import zipfile
import re

def extraer_texto_docx(ruta):
    with zipfile.ZipFile(ruta) as z:
        xml = z.read('word/document.xml').decode('utf-8')

```

```
# Eliminar etiquetas XML
texto = re.sub(r'<[^>]+>', ' ', xml)
texto = re.sub(r'\s+', ' ', texto).strip()
return texto
```

8.8 Manejo de rutas con pathlib

La librería pathlib ofrece una forma más moderna de trabajar con rutas:

```
from pathlib import Path

carpeta = Path('/ruta/a/mis/datos')
archivo = carpeta / 'campana_oct2025' / 'corrientes.csv'

archivo.exists()          # True/False
archivo.suffix             # '.csv'
archivo.stem              # 'corrientes'
archivo.parent            # carpeta Los Vilos
archivo.name              # 'corrientes.csv'

# Listar archivos
list(carpeta.glob('*.xlsx'))
list(carpeta.rglob('*.csv')) # recursivo
```

□ **Rutas en Windows desde WSL** — Al usar Python desde WSL (Windows Subsystem for Linux), las rutas de Windows se acceden como /mnt/c/.... Las rutas con espacios deben ir entre comillas o manejarse con Path: `python ruta = Path('/mnt/c/Users/Usuario/Mi Carpeta/archivo.csv')`

9 Matplotlib

Matplotlib es la librería de visualización estándar en Python. Permite crear desde gráficos simples hasta figuras multipanel complejas listas para publicación.

```
import matplotlib.pyplot as plt
import numpy as np
```

9.1 Gráfico básico

```
tiempo = np.arange(0, 186)
velocidad = np.random.normal(3.93, 2.8, 186)

plt.figure(figsize=(12, 4))
plt.plot(tiempo, velocidad, color='steelblue', linewidth=0.8)
plt.xlabel('Día')
plt.ylabel('Velocidad (m/s)')
plt.title('Serie temporal de velocidad del viento')
plt.tight_layout()
plt.savefig('serie_viento.png', dpi=150)
plt.show()
```




Figura 1: Serie temporal con título calculado

9.2 Figure y Axes — la estructura correcta

Para figuras con múltiples paneles o más control, se trabaja directamente con objetos Figure y Axes:

```
fig, ax = plt.subplots(figsize=(12, 4))

ax.plot(tiempo, velocidad, color='steelblue', linewidth=0.8)
ax.set_xlabel('Día')
ax.set_ylabel('Velocidad (m/s)')
ax.set_title('Serie temporal')
```

```
ax.grid(True, alpha=0.3)

fig.tight_layout()
fig.savefig('serie_viento.png', dpi=150)
```

9.3 Múltiples paneles

9.3.1 subplot simple

```
fig, axes = plt.subplots(3, 1, figsize=(12, 10), sharex=True)

axes[0].plot(tiempo, Hm0, color='navy')
axes[0].set_ylabel('Hm0 (m)')

axes[1].plot(tiempo, Tm, color='teal')
axes[1].set_ylabel('Tm (s)')

axes[2].plot(tiempo, Dm, color='darkorange', marker='.', markersize=1,
             ↪ linestyle='none')
axes[2].set_ylabel('Dm (°)')
axes[2].set_xlabel('Tiempo')

fig.tight_layout()
```

9.3.2 subplot2grid — paneles de distinto tamaño

```
fig = plt.figure(figsize=(14, 8))

ax1 = plt.subplot2grid((2, 3), (0, 0), colspan=2) # fila 0, cols 0-1
ax2 = plt.subplot2grid((2, 3), (0, 2))          # fila 0, col 2
ax3 = plt.subplot2grid((2, 3), (1, 0), colspan=3) # fila 1, ancho completo
```

9.4 Tipos de gráfico

```
# Línea
ax.plot(x, y, color='steelblue', linewidth=1, linestyle='--', label='velocidad')

# Puntos
ax.scatter(x, y, c=colores, s=20, alpha=0.5, cmap='viridis')

# Barras
ax.bar(meses, promedios, color='teal', edgecolor='white')

# Histograma
```




Figura 2: Tres paneles con sharex

```

ax.hist(velocidad, bins=20, color='steelblue', edgecolor='white', density=True)

# Área rellena
ax.fill_between(tiempo, y_min, y_max, alpha=0.3, color='steelblue')

# Línea horizontal / vertical de referencia
ax.axhline(y=6, color='red', linestyle='--', linewidth=0.8, label='umbral')
ax.axvline(x=45, color='gray', linestyle=':')

```

9.5 Colores y estilos

```

# Colores nombrados
'steelblue', 'navy', 'teal', 'darkorange', 'firebrick', 'gray'

# Hex
'#2196F3'

# Escala de grises
'0.5' # gris medio

# Transparencia
ax.plot(x, y, color='steelblue', alpha=0.7)

# Colormaps – para datos continuos
cmap = plt.cm.viridis
cmap = plt.cm.RdBu_r # divergente, útil para anomalías

```

9.6 Ejes y etiquetas

```

ax.set_xlim(0, 186)
ax.set_ylim(0, 20)

# Ticks personalizados
ax.set_xticks([0, 30, 60, 90, 120, 150, 180])
ax.set_xticklabels(['sep', 'oct', 'nov', 'dic', 'ene', 'feb', 'mar'])
ax.tick_params(axis='x', rotation=45)

# Formato de números en eje
from matplotlib.ticker import PercentFormatter
ax.yaxis.set_major_formatter(PercentFormatter(decimals=1))

# Escala logarítmica
ax.set_yscale('log')

```

9.7 Leyenda y anotaciones

```
ax.plot(x, y1, label='Velocidad media')
ax.plot(x, y2, label='Percentil 95')
ax.legend(loc='upper right', fontsize=9)

# Anotación de texto
ax.text(0.02, 0.95, f'Máximo: {vmax:.2f} m/s',
        transform=ax.transAxes, # coordenadas relativas al axes (0-1)
        fontsize=9, verticalalignment='top')

# Flecha con texto
ax.annotate('Evento energético', xy=(45, 3.0), xytext=(60, 3.5),
           arrowprops=dict(arrowstyle='->', color='red'))
```

9.8 Mapas de calor (heatmap)

Muy usado en corrientes para visualizar velocidad por tiempo y profundidad:

```
# datos: matriz (n_tiempos × n_profundidades)
im = ax.pcolormesh(tiempos, profundidades, datos.T,
                  cmap='RdBu_r', vmin=-0.3, vmax=0.3)
fig.colorbar(im, ax=ax, label='Velocidad (m/s)')
ax.set_ylabel('Profundidad (m)')
ax.invert_yaxis() # profundidad creciente hacia abajo
```




Figura 3: Heatmap de corrientes

9.9 Guardar figuras

```
fig.savefig('figura.png', dpi=150, bbox_inches='tight')
fig.savefig('figura.pdf', bbox_inches='tight') # vectorial
fig.savefig('figura.svg', bbox_inches='tight') # vectorial editable
```

```
plt.close(fig) # liberar memoria – importante en scripts que generan muchas figuras
```

9.9.1 PDF multipágina

```
from matplotlib.backends.backend_pdf import PdfPages
```

```
with PdfPages('informe_figuras.pdf') as pdf:
    for mes in meses:
        fig, ax = plt.subplots()
        ax.plot(datos_mes[mes])
        ax.set_title(mes)
        pdf.savefig(fig)
        plt.close(fig)
```

9.10 Figuras con valores calculados

En análisis real, los títulos, etiquetas y leyendas deben mostrar valores del propio conjunto de datos — no texto fijo. Así la figura se documenta a sí misma.




Figura 4: Anotaciones y leyenda con valores calculados

9.10.1 Título y subtítulo con estadísticas

```
import matplotlib.pyplot as plt
import numpy as np

velocidad = np.array([1.2, 3.4, 2.1, 4.5, 0.8, 3.9, 2.7])

fig, ax = plt.subplots(figsize=(10, 4))
```

```

ax.plot(velocidad, color='steelblue', linewidth=1.2)

# Calcular estadísticas para usar en el título
v_media = velocidad.mean()
v_max = velocidad.max()
n = len(velocidad)

ax.set_title(f'Serie temporal de velocidad | media={v_media:.2f} m/s
↳ máx={v_max:.2f} m/s n={n}')
ax.set_xlabel('Muestra')
ax.set_ylabel('Velocidad (m/s)')
fig.tight_layout()

```

9.10.2 Leyendas con valores calculados

```

profundidades = [5, 10, 20]
datos = {
    5: np.random.normal(2.5, 0.8, 186),
    10: np.random.normal(1.8, 0.6, 186),
    20: np.random.normal(0.9, 0.4, 186),
}

fig, ax = plt.subplots(figsize=(12, 4))

for prof, serie in datos.items():
    media = serie.mean()
    # La etiqueta de la leyenda incluye el valor calculado
    ax.plot(serie, label=f'{prof} m (media={media:.2f} m/s)', linewidth=0.8)

ax.set_xlabel('Tiempo (días)')
ax.set_ylabel('Velocidad (m/s)')
ax.legend(loc='upper right', fontsize=9)
fig.tight_layout()

```

9.10.3 Anotaciones sobre el gráfico

```

fig, ax = plt.subplots(figsize=(10, 4))
ax.plot(velocidad, color='steelblue', linewidth=1.2)

# Marcar el máximo con una anotación
idx_max = velocidad.argmax()
v_max = velocidad[idx_max]

ax.annotate(
    f'máx: {v_max:.2f} m/s',

```

```

    xy=(idx_max, v_max),          # punto al que apunta la flecha
    xytext=(idx_max + 0.5, v_max + 0.3), # posición del texto
    arrowprops=dict(arrowstyle='->', color='firebrick'),
    fontsize=9, color='firebrick'
)

# Línea de referencia con su propio label
umbral = 3.0
ax.axhline(umbral, color='gray', linestyle='--', linewidth=0.8,
           label=f'umbral operacional: {umbral} m/s')
ax.legend(fontsize=9)
fig.tight_layout()

```

9.10.4 Texto estadístico dentro del panel

```

fig, ax = plt.subplots(figsize=(10, 4))
ax.plot(velocidad, color='steelblue')

# Bloque de estadísticas en esquina del axes
stats_texto = (
    f"media = {velocidad.mean():.2f} m/s\n"
    f"DE     = {velocidad.std():.2f} m/s\n"
    f"máx    = {velocidad.max():.2f} m/s\n"
    f"n      = {len(velocidad)}"
)
ax.text(
    0.02, 0.97, stats_texto,
    transform=ax.transAxes,          # coordenadas 0-1 relativas al panel
    fontsize=8, verticalalignment='top',
    fontfamily='monospace',
    bbox=dict(boxstyle='round', facecolor='white', alpha=0.8)
)
fig.tight_layout()

```

9.10.5 Título desde metadatos del archivo

```

import pandas as pd

df = pd.read_csv('corrientes_oct2025.csv', parse_dates=['fecha'])

fecha_ini = df['fecha'].min().strftime('%d %b %Y')
fecha_fin = df['fecha'].max().strftime('%d %b %Y')
n_dias    = (df['fecha'].max() - df['fecha'].min()).days

fig, ax = plt.subplots(figsize=(12, 4))

```



```

ax.plot(df['fecha'], df['velocidad'], linewidth=0.8)
ax.set_title(f'Velocidad de corriente – {fecha_ini} al {fecha_fin} ({n_dias} días)')
ax.set_xlabel('Fecha')
ax.set_ylabel('Velocidad (m/s)')
fig.autofmt_xdate()    # rota etiquetas de fecha automáticamente
fig.tight_layout()

```

9.11 Backend gráfico

El backend controla cómo se muestran las figuras:

```

import matplotlib
matplotlib.use('Qt5Agg')    # ventana interactiva (ideal en Spyder)
# o
matplotlib.use('Agg')       # sin ventana, solo guardar a archivo (ideal en scripts
↳ automáticos)

```

En Spyder se configura desde **Preferences → IPython console → Graphics → Backend**.

► **plt.close() en scripts automáticos** — Cuando un script genera decenas de figuras (como el autoinforme), es importante cerrar cada figura después de guardarla con `plt.close(fig)`. De lo contrario Matplotlib acumula todas en memoria y Spyder puede volverse lento o colapsar.

10 Rosas de viento y diagramas polares

Las rosas de dirección y los diagramas polares son las figuras más características del análisis oceanográfico. Se usan para visualizar la distribución de velocidades y direcciones del viento, corrientes y oleaje.

10.1 Rosa de viento con windrose

La librería windrose genera rosas directamente desde arrays de velocidad y dirección:

```
from windrose import WindroseAxes
import matplotlib.pyplot as plt
import numpy as np

fig = plt.figure(figsize=(7, 7))
ax = WindroseAxes.from_ax(fig=fig)

ax.bar(
    direccion,          # array de direcciones (°, convención meteorológica: FROM)
    velocidad,          # array de velocidades (m/s)
    normed=True,        # mostrar como porcentaje
    opening=0.9,
    edgecolor='white',
    bins=[0, 2, 4, 6, 8, 10], # intervalos de velocidad
    cmap=plt.cm.YlOrRd
)

ax.set_legend(title='Velocidad (m/s)', loc='lower right')
ax.set_title('Rosa de viento – Los Vilos')

fig.savefig('rosa_viento.png', dpi=150, bbox_inches='tight')
plt.close(fig)
```

10.2 Rosa de corrientes (sin windrose)

Para corrientes se suele hacer una rosa manual usando proyección polar de Matplotlib, con más control sobre el diseño:

```
import matplotlib.pyplot as plt
import numpy as np

def rosa_corrientes(direcciones, velocidades, titulo='', ax=None):
    """Rosa de corrientes en 8 octantes."""
    octantes = np.arange(0, 360, 45)
    etiquetas = ['N', 'NE', 'E', 'SE', 'S', 'SO', 'O', 'NO']
    colores_vel = plt.cm.Blues(np.linspace(0.3, 1.0, 4))
    bins_vel = [0, 0.05, 0.1, 0.2, np.inf]
    labels_vel = ['0–0.05', '0.05–0.1', '0.1–0.2', '>0.2']
```

```

if ax is None:
    fig, ax = plt.subplots(subplot_kw={'projection': 'polar'}, figsize=(6, 6))

# Orientar norte arriba, sentido horario
ax.set_theta_zero_location('N')
ax.set_theta_direction(-1)

ancho = np.radians(45) * 0.85
bottom = np.zeros(8)

for i, (vmin, vmax) in enumerate(zip(bins_vel[:-1], bins_vel[1:])):
    mask = (velocidades >= vmin) & (velocidades < vmax)
    conteos = np.zeros(8)
    for j, oct in enumerate(octantes):
        mask_dir = (direcciones >= oct - 22.5) & (direcciones < oct + 22.5)
        conteos[j] = np.sum(mask & mask_dir)

    pct = conteos / len(velocidades) * 100
    theta = np.radians(octantes)
    ax.bar(theta, pct, width=ancho, bottom=bottom,
           color=colores_vel[i], label=labels_vel[i], edgecolor='white',
    ↪ linewidth=0.5)
    bottom += pct

ax.set_xticks(np.radians(octantes))
ax.set_xticklabels(etiquetas)
ax.set_title(titulo, pad=15)
ax.legend(title='Vel (m/s)', loc='lower right', bbox_to_anchor=(1.3, -0.1))

return ax

```

10.3 Diagrama polar de dispersión

Muestra la distribución conjunta de velocidad y dirección, con cada punto representando un registro:

```

fig, ax = plt.subplots(subplot_kw={'projection': 'polar'}, figsize=(7, 7))
ax.set_theta_zero_location('N')
ax.set_theta_direction(-1)

sc = ax.scatter(
    np.radians(direccion),
    velocidad,
    c=velocidad,           # color según velocidad
    cmap='YlOrRd',
    s=3,

```

```

    alpha=0.4
)

# Marcar el máximo
idx_max = np.argmax(velocidad)
ax.scatter(np.radians(direccion[idx_max]), velocidad[idx_max],
           c='red', s=80, zorder=5, label=f'Máx: {velocidad[idx_max]:.2f} m/s')

fig.colorbar(sc, ax=ax, label='Velocidad (m/s)', shrink=0.7)
ax.set_title('Diagrama polar de dispersión')
ax.legend(loc='lower right')

```

10.4 Vector progresivo

El vector progresivo acumula el desplazamiento (U, V) a lo largo del tiempo, mostrando la trayectoria resultante:

```

def vector_progresivo(velocidad, direccion, dt_horas=0.167):
    """
    Calcula el vector progresivo.
    dt_horas: intervalo entre registros en horas (10 min = 0.167 h)
    """
    u = velocidad * np.sin(np.radians(direccion))
    v = velocidad * np.cos(np.radians(direccion))

    # Desplazamiento acumulado en km
    x = np.cumsum(u * dt_horas * 3.6)  # m/s × h × 3.6 → km
    y = np.cumsum(v * dt_horas * 3.6)

    return x, y

# Graficar
x, y = vector_progresivo(vel_prof, dir_prof)

fig, ax = plt.subplots(figsize=(6, 6))
ax.plot(x, y, color='steelblue', linewidth=0.8)
ax.plot(0, 0, 'go', markersize=8, label='Inicio')
ax.plot(x[-1], y[-1], 'r*', markersize=12, label=f'Final:
↪ {np.sqrt(x[-1]**2+y[-1]**2):.1f} km')
ax.axhline(0, color='gray', linewidth=0.5)
ax.axvline(0, color='gray', linewidth=0.5)
ax.set_xlabel('Desplazamiento E-O (km)')
ax.set_ylabel('Desplazamiento N-S (km)')
ax.set_aspect('equal')
ax.legend()
ax.set_title('Vector progresivo')

```

10.5 Patrón diario

Gráfico de líneas por mes mostrando el ciclo horario de la velocidad:

```
import pandas as pd

# df tiene índice DatetimeIndex
patron = df.groupby([df.index.month,
    ↪ df.index.hour])['velocidad'].mean().unstack(level=0)
# patron: filas=hora (0-23), columnas=mes (1-12)

nombres_meses = {9:'Sep', 10:'Oct', 11:'Nov', 12:'Dic', 1:'Ene', 2:'Feb', 3:'Mar'}
colores_meses = plt.cm.tab10(np.linspace(0, 1, 12))

fig, ax = plt.subplots(figsize=(10, 5))

for mes, col in zip(patron.columns, colores_meses):
    ax.plot(patron.index, patron[mes], label=nombres_meses.get(mes, mes),
            color=col, linewidth=1.2)

# Promedio global
ax.plot(patron.index, patron.mean(axis=1),
        color='black', linewidth=2.5, linestyle='--', label='Promedio global')

ax.set_xlabel('Hora del día (UTC-3)')
ax.set_ylabel('Velocidad media (m/s)')
ax.set_title('Patrón diario de velocidad del viento')
ax.set_xticks(range(0, 24, 2))
ax.set_xticklabels([f'{h:02d}:00' for h in range(0, 24, 2)], rotation=45)
ax.legend(ncol=4, fontsize=8)
ax.grid(True, alpha=0.3)
fig.tight_layout()
```

► **Convención de dirección** — En meteorología la dirección indica desde dónde viene el viento (FROM). En oceanografía de corrientes, la convención es hacia dónde va (TO). Al graficar rosas, hay que tener claro cuál convención se está usando para que la rosa tenga sentido físico.

11 Figuras para informes

En un pipeline de informes automatizados las figuras no solo se visualizan en Spyder, sino que se guardan como archivos PNG para luego insertarlas en el informe Word. Esto implica cuidar resolución, tamaño, fuente y nomenclatura de archivos.

11.1 Estilo consistente

Definir un estilo base al comienzo del script garantiza que todas las figuras tengan el mismo aspecto:

```
import matplotlib.pyplot as plt
import matplotlib as mpl

# Estilo global
mpl.rcParams.update({
    'font.family':      'sans-serif',
    'font.size':        10,
    'axes.titlesize':   11,
    'axes.labelsize':   10,
    'xtick.labelsize':  9,
    'ytick.labelsize':  9,
    'legend.fontsize':  9,
    'figure.dpi':       100,
    'axes.grid':        True,
    'grid.alpha':       0.3,
    'axes.spines.top':  False,
    'axes.spines.right':False,
})
```

O usar un estilo predefinido:

```
plt.style.use('seaborn-v0_8-whitegrid')
```

11.2 Guardar con calidad para informe

```
fig.savefig(
    ruta_figura,
    dpi=150,          # 150 dpi es suficiente para Word
    bbox_inches='tight', # elimina márgenes en blanco
    facecolor='white'   # fondo blanco (no transparente)
)
plt.close(fig)
```

11.3 Nomenclatura de archivos de figura

El autoinforme busca las figuras por nombre. Es importante seguir una convención estricta:

```
import os

carpeta_figuras = os.path.join(ruta_proyecto, 'figuras_magnitud')
os.makedirs(carpeta_figuras, exist_ok=True)

# Nomenclatura usada en el pipeline de corrientes
fig_serie.savefig( os.path.join(carpeta_figuras, 'serie_velocidad.png'),
    ↪ dpi=150, bbox_inches='tight')
fig_rosa.savefig( os.path.join(carpeta_figuras, 'rosa_corrientes_3m.png'),
    ↪ dpi=150, bbox_inches='tight')
fig_heatmap.savefig( os.path.join(carpeta_figuras, 'heatmap_velocidad.png'),
    ↪ dpi=150, bbox_inches='tight')
```

11.4 Figuras por profundidad

Cuando se genera una figura por cada profundidad (rosas, vectores progresivos), se itera sobre las capas y se guarda con sufijo:

```
profundidades = [3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23]

for prof in profundidades:
    fig, ax = plt.subplots(subplot_kw={'projection': 'polar'}, figsize=(6, 6))

    vel_capa = df[df['profundidad'] == prof]['velocidad'].values
    dir_capa = df[df['profundidad'] == prof]['direccion'].values

    # ... graficar ...

    nombre = f'rosa_corrientes_{prof}m.png'
    fig.savefig(os.path.join(carpeta_figuras, nombre), dpi=150, bbox_inches='tight')
    plt.close(fig)
    print(f' Figura guardada: {nombre}')
```

11.5 Ciclo anual mensual

Para el informe de viento se genera una figura por mes con barras de percentiles:

```
fig, ax = plt.subplots(figsize=(10, 5))

meses_nombres = ['Sep', 'Oct', 'Nov', 'Dic', 'Ene', 'Feb', 'Mar']
x = np.arange(len(meses_nombres))

ax.bar(x, promedios, color='steelblue', label='Promedio', zorder=3)
```

```

ax.vlines(x, p05, p95, color='navy', linewidth=2, label='P5-P95', zorder=4)
ax.scatter(x, maximos, color='firebrick', s=40, zorder=5, label='Máximo')

ax.set_xticks(x)
ax.set_xticklabels(meses_nombres)
ax.set_ylabel('Velocidad (m/s)')
ax.set_title('Ciclo anual de velocidad del viento')
ax.legend()
fig.tight_layout()
fig.savefig(os.path.join(carpeta_figuras, 'ciclo_anual.png'), dpi=150,
    ↪ bbox_inches='tight')
plt.close(fig)

```

11.6 Insertar figuras en Word

Una vez guardadas, las figuras se insertan en la plantilla Word desde el autoinforme. El proceso se describe en detalle en el capítulo de python-docx, pero el patrón básico es:

```

from docx import Document
from docx.shared import Cm

doc = Document('plantilla.docx')

for parrafo in doc.paragraphs:
    if '[FIGURA_ROSA]' in parrafo.text:
        parrafo.clear()
        run = parrafo.add_run()
        run.add_picture('figuras_magnitud/rosa_corrientes_3m.png', width=Cm(12))
        break

doc.save('informe_final.docx')

```

11.7 Figura multipanel para series de oleaje

El informe incluye una figura con tres paneles sincronizados (Hm0, Tm, Dm):

```

fig, axes = plt.subplots(3, 1, figsize=(14, 8), sharex=True,
    gridspec_kw={'hspace': 0.08})

# Panel 1: Altura Hm0
axes[0].plot(df.index, df['Hm0'], color='navy', linewidth=0.7)
axes[0].set_ylabel('Hm0 (m)')
axes[0].set_ylim(0, df['Hm0'].max() * 1.1)

# Panel 2: Periodo Tm
axes[1].plot(df.index, df['Tm'], color='teal', linewidth=0.7)

```



```

axes[1].set_ylabel('Tm (s)')

# Panel 3: Dirección Dm (puntos, no línea)
axes[2].scatter(df.index, df['Dm'], s=1, color='darkorange', alpha=0.6)
axes[2].set_ylabel('Dm (°)')
axes[2].set_ylim(0, 360)
axes[2].set_yticks([0, 90, 180, 270, 360])
axes[2].set_yticklabels(['N', 'E', 'S', 'O', 'N'])
axes[2].set_xlabel('Fecha')

# Formatear eje X con fechas
import matplotlib.dates as mdates
axes[2].xaxis.set_major_formatter(mdates.DateFormatter('%b %Y'))
axes[2].xaxis.set_major_locator(mdates.MonthLocator())
plt.setp(axes[2].xaxis.get_majorticklabels(), rotation=30, ha='right')

fig.savefig('serie_oleaje.png', dpi=150, bbox_inches='tight')
plt.close(fig)

```

► **Cuándo usar sharex=True** — En series temporales con múltiples variables (Hm0, Tm, Dm), sharex=True sincroniza el zoom y el paneo entre paneles. Si el usuario hace zoom en un panel en Spyder, todos los demás se actualizan juntos.

12 Estadísticas circulares

Los datos de dirección (viento, corrientes, oleaje) son **circulares**: 0° y 360° son el mismo ángulo, por lo que promediar linealmente da resultados absurdos. Si una serie tiene mediciones de 10° y 350° , el promedio lineal es 180° (Sur), pero el promedio circular correcto es 0° (Norte). Python incluye herramientas para manejar esta circularidad correctamente.

12.1 Media y desviación estándar circular

scipy.stats provee circmean y circstd que trabajan directamente en grados o radianes:

```
from scipy.stats import circmean, circstd
import numpy as np

# Las funciones esperan radianes por defecto; high/low definen el rango
direcciones_deg = np.array([350, 5, 10, 355, 2, 358])

media_circ = circmean(direcciones_deg, high=360, low=0)
std_circ = circstd(direcciones_deg, high=360, low=0)

print(f"Media circular: {media_circ:.1f}°")
print(f"Desv. estándar: {std_circ:.1f}°")
```

12.1.1 Cálculo manual con vectores unitarios

El mismo resultado se obtiene convirtiendo cada ángulo a un vector unitario y promediando sus componentes:

```
def media_circular(angulos_deg):
    rad = np.radians(angulos_deg)
    sin_m = np.nanmean(np.sin(rad))
    cos_m = np.nanmean(np.cos(rad))
    media = np.degrees(np.arctan2(sin_m, cos_m)) % 360
    return media

def concentracion_circular(angulos_deg):
    """Longitud del vector resultante medio ( $R^-$ ). Rango [0, 1]: 1 = perfectamente
    ↪ concentrado."""
    rad = np.radians(angulos_deg)
    sin_m = np.nanmean(np.sin(rad))
    cos_m = np.nanmean(np.cos(rad))
    return np.sqrt(sin_m**2 + cos_m**2)

print(f"Media: {media_circular(direcciones_deg):.1f}°")
print(f"Concentración  $\bar{R}$ : {concentracion_circular(direcciones_deg):.3f}")
```

12.2 Dirección predominante

La dirección predominante no es necesariamente la media circular; en vientos bimodales (p. ej. brisa diurna que alterna Norte/Sur) la media puede apuntar a un sector vacío. En ese caso se usa la **moda** por octante:

```
def direccion_predominante(direcciones_deg, n_sectores=8):
    """Retorna el centro del sector con mayor frecuencia."""
    ancho = 360 / n_sectores
    sectores = (np.floor((direcciones_deg % 360) / ancho) * ancho + ancho /
↪ 2).astype(int)
    valores, conteos = np.unique(sectores, return_counts=True)
    return valores[np.argmax(conteos)]

print(f"Dirección predominante: {direccion_predominante(direcciones_deg)}°")
```

12.3 Diferencia angular

Para calcular la diferencia entre dos ángulos de forma correcta (resultado siempre en $[-180^\circ, 180^\circ]$):

```
def diferencia angular(a, b):
    """Diferencia a - b en el rango [-180, 180]."""
    diff = (a - b + 180) % 360 - 180
    return diff

# Ejemplo: diferencia entre dirección modelada y observada
dir_modelo = 320.0
dir_obs = 15.0
print(f"Diferencia: {diferencia angular(dir_modelo, dir_obs):.1f}°")
# → -55.0° (el modelo es 55° más hacia el oeste)
```

12.4 Error cuadrático medio circular

Métrica estándar para evaluar el desempeño de un modelo de dirección:

```
def rmse_circular(dir_modelo, dir_obs):
    diffs = diferencia angular(np.asarray(dir_modelo), np.asarray(dir_obs))
    return np.sqrt(np.nanmean(diffs**2))

# Comparar dirección de corriente modelada vs. medida
rmse_dir = rmse_circular(df['dir_modelo'], df['dir_obs'])
print(f"RMSE direccional: {rmse_dir:.1f}°")
```

12.5 Estadísticas por sector en el pipeline

En el autoinforme de corrientes se calculan estadísticas separadas por octante para la tabla de incidencia:

```

import pandas as pd

def tabla_incidencia(df, col_vel, col_dir, n_sectores=8):
    """
    Retorna DataFrame con frecuencia, velocidad media y máxima por sector.
    """
    ancho = 360 / n_sectores
    nombres_sectores = ['N', 'NE', 'E', 'SE', 'S', 'SO', 'O', 'NO']

    # Asignar sector a cada registro
    df = df.copy()
    df['sector_idx'] = (np.floor((df[col_dir] % 360) / ancho)).astype(int) %
    ↪ n_sectores
    df['sector'] = df['sector_idx'].map(dict(enumerate(nombres_sectores)))

    resumen = df.groupby('sector').agg(
        n=(col_vel, 'count'),
        vel_media=(col_vel, 'mean'),
        vel_max=(col_vel, 'max')
    )
    resumen['frecuencia_%'] = (resumen['n'] / len(df) * 100).round(1)

    return resumen[['frecuencia_%', 'vel_media', 'vel_max']]

tabla = tabla_incidencia(df_corrientes, 'velocidad', 'direccion')
print(tabla.to_string())

```

12.6 Histograma direccional

Visualizar la distribución de direcciones en una barra circular es más informativo que un histograma cartesiano:

```

import matplotlib.pyplot as plt

def histograma_direccional(direcciones_deg, n_sectores=16, titulo=''):
    ancho = 360 / n_sectores
    bordes = np.arange(0, 361, ancho)
    conteos, _ = np.histogram(direcciones_deg % 360, bins=bordes)
    centros = bordes[:-1] + ancho / 2

    fig, ax = plt.subplots(subplot_kw={'projection': 'polar'}, figsize=(6, 6))
    ax.set_theta_zero_location('N')
    ax.set_theta_direction(-1)

    theta = np.radians(centros)
    ax.bar(theta, conteos / len(direcciones_deg) * 100,
           width=np.radians(ancho * 0.85),

```

```
color='steelblue', edgecolor='white', alpha=0.8)

ax.set_title(titulo or 'Distribución direccional (%)', pad=15)
return fig, ax
```

► **Calma o datos faltantes** — Cuando la velocidad es cero (calma), la dirección no tiene significado físico. Antes de calcular estadísticas circulares, filtrar los registros con velocidad inferior al umbral de arranque del instrumento (típicamente 0.02 m/s en correntómetros, 0.5 m/s en anemómetros).

13 Análisis espectral

El análisis espectral descompone una serie temporal en sus componentes de frecuencia, mostrando cuánta energía hay en cada período. En oceanografía se aplica principalmente al oleaje (para obtener el espectro de energía y extraer parámetros como H_{m0} y T_p) y a las corrientes (para identificar mareas, inerciales y otras señales periódicas).

13.1 Transformada de Fourier con NumPy

La FFT es el punto de partida para cualquier análisis espectral:

```
import numpy as np

# Serie temporal de velocidad de corriente (N datos, dt segundos entre muestras)
N = len(serie)
dt = 600 # 10 minutos en segundos
fs = 1 / dt # frecuencia de muestreo (Hz)

# FFT
espectro = np.fft.rfft(serie - serie.mean()) # rfft: solo frecuencias positivas
freqs = np.fft.rfftfreq(N, d=dt) # Hz

# Potencia espectral
potencia = (np.abs(espectro) ** 2) / (N * fs)

# Convertir frecuencias a períodos (en horas)
with np.errstate(divide='ignore'):
    periodos_h = 1 / freqs / 3600
```

13.2 Densidad espectral de potencia con Welch

El método de Welch es más robusto que la FFT directa porque promedia segmentos solapados, reduciendo el ruido estadístico:

```
from scipy.signal import welch

# nperseg: número de muestras por segmento (elegir ~10% de N, potencia de 2)
freqs_w, psd = welch(
    serie - serie.mean(),
    fs=fs,
    nperseg=512,
    noverlap=256,
    window='hann'
)

periodos_w_h = 1 / freqs_w / 3600
```

```

import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(10, 5))
ax.semilogy(periodos_w_h, psd, color='navy', linewidth=0.8)
ax.set_xlim(0, 50) # periodos hasta 50 h
ax.set_xlabel('Período (h)')
ax.set_ylabel('PSD ((m/s)2/Hz)')
ax.set_title('Espectro de densidad de potencia – Corriente 7 m')
ax.grid(True, which='both', alpha=0.3)

# Marcar componentes de marea
for periodo, nombre in [(24, 'K1'), (12.42, 'M2'), (6.21, 'M4')]:
    ax.axvline(periodo, color='firebrick', linewidth=0.8, linestyle='--', alpha=0.7)
    ax.text(periodo, ax.get_ylim()[1] * 0.5, nombre, color='firebrick', fontsize=8)

```

13.3 Espectro de oleaje

Los parámetros integrados (H_{m0} , T_{m02} , T_p) se derivan del espectro de densidad de energía:

```

def espectro_oleaje(eta, dt_s, nperseg=512):
    """
    Calcula el espectro de energía de una serie de superficie libre.
    Retorna freqs (Hz) y S (m2/Hz).
    """
    freqs, psd = welch(eta - eta.mean(), fs=1/dt_s,
                       nperseg=nperseg, window='hann')
    return freqs[1:], psd[1:] # descartar componente DC

def momento_espectral(freqs, S, n):
    """Momento espectral de orden n:  $m_n = \int f^n S(f) df$ ."""
    return np.trapz(freqs**n * S, freqs)

freqs, S = espectro_oleaje(eta, dt_s=1800) # muestras cada 30 min

m0 = momento_espectral(freqs, S, 0)
m2 = momento_espectral(freqs, S, 2)

Hm0 = 4 * np.sqrt(m0) # altura significativa espectral (m)
Tm02 = np.sqrt(m0 / m2) # período medio (s)
Tp = 1 / freqs[np.argmax(S)] # período de pico (s)

print(f"Hm0 = {Hm0:.2f} m")
print(f"Tm02 = {Tm02:.1f} s")
print(f"Tp = {Tp:.1f} s")

```

13.4 Visualizar el espectro de oleaje

```
fig, ax = plt.subplots(figsize=(9, 5))

ax.fill_between(freqs, S, alpha=0.3, color='steelblue')
ax.plot(freqs, S, color='navy', linewidth=1)

# Marcar frecuencia de pico
fp = freqs[np.argmax(S)]
ax.axvline(fp, color='firebrick', linestyle='--', linewidth=1,
          label=f'fp = {fp:.4f} Hz (Tp = {1/fp:.1f} s)')

# Separar swell y viento localmente (límite convencional 0.1 Hz)
ax.axvspan(freqs.min(), 0.1, alpha=0.08, color='green', label='Swell (<0.1 Hz)')
ax.axvspan(0.1, freqs.max(), alpha=0.08, color='orange', label='Sea (>0.1 Hz)')

ax.set_xlabel('Frecuencia (Hz)')
ax.set_ylabel('S(f) (m2/Hz)')
ax.set_title(f'Espectro de oleaje - Hm0 = {Hm0:.2f} m, Tp = {Tp:.1f} s')
ax.legend(fontsize=9)
ax.grid(True, alpha=0.3)
fig.tight_layout()
```

13.5 Identificar componentes de marea

Las mareas son señales periódicas con frecuencias bien conocidas:

```
MAREAS = {
    'K1': 23.93,    # diurna
    'O1': 25.82,
    'M2': 12.42,    # semidiurna principal
    'S2': 12.00,
    'N2': 12.66,
    'M4': 6.21,     # cuarto-diurna
}

import pandas as pd

df_mareas = []
for nombre, periodo_h in MAREAS.items():
    f_central = 1 / (periodo_h * 3600)
    mascara = np.abs(freqs_w - f_central) < f_central * 0.05
    if mascara.any():
        energia = np.trapz(psd[mascara], freqs_w[mascara])
        df_mareas.append({'componente': nombre, 'período_h': periodo_h, 'energía':
            ↪ energia})
```



```
df_m = pd.DataFrame(df_mareas).sort_values('energía', ascending=False)
print(df_m.to_string(index=False))
```

13.6 Espectrograma (espectro en tiempo)

Para ver cómo evoluciona el espectro a lo largo del tiempo:

```
from scipy.signal import spectrogram

f_sg, t_sg, Sxx = spectrogram(
    serie - serie.mean(),
    fs=fs,
    nperseg=256,
    noverlap=192,
    window='hann'
)

fig, ax = plt.subplots(figsize=(12, 5))
im = ax.pcolormesh(t_sg / 3600, 1 / f_sg[1:] / 3600, np.log10(Sxx[1:]),
                  cmap='viridis', shading='gouraud')
ax.set_ylim(0, 30) # períodos hasta 30 h
ax.set_xlabel('Tiempo (h)')
ax.set_ylabel('Período (h)')
ax.set_title('Espectrograma de velocidad de corriente')
fig.colorbar(im, ax=ax, label='log10 PSD')
```

► **Efecto de ventana** — Aplicar una ventana (Hann, Hamming) antes de la FFT reduce las fugas espectrales causadas por el truncamiento de la serie. `welch` aplica la ventana internamente; si usas `np.fft.rfft` directamente, multiplica la serie por `np.hanning(N)` antes de transformar.

□ **Resolución espectral** — La resolución frecuencial es $\Delta f = 1 / (N \times dt)$. Series cortas tienen baja resolución y no pueden separar componentes de período similar (p. ej. M2 y S2, que difieren solo 0.42 h). Para estudios de marea se necesitan al menos 30 días de datos.

14 Filtros e interpolación

Los datos oceanográficos rara vez llegan limpios: tienen ruido de alta frecuencia, datos faltantes (NaN) y resolución temporal variable. El filtrado elimina frecuencias no deseadas; la interpolación rellena huecos; el remuestreo homogeneiza la resolución temporal. Estas tres operaciones son parte estándar de cualquier pipeline de preprocesamiento.

14.1 Media móvil (filtro de paso bajo simple)

Es el filtro más sencillo y el más rápido de aplicar con pandas:

```
import pandas as pd

# Ventana de 1 hora en datos de 10 min → 6 muestras
df['vel_suavizada'] = df['velocidad'].rolling(window=6, center=True).mean()

# Con mínimo de datos para no producir NaN en los extremos
df['vel_suavizada'] = df['velocidad'].rolling(window=6, center=True,
    ↪ min_periods=3).mean()
```

La media móvil atenúa bien el ruido pero tiene una respuesta de frecuencia imperfecta: no rechaza completamente las frecuencias altas y tiene fugas. Para filtrado más preciso se usa Butterworth.

14.2 Filtro Butterworth (scipy)

El filtro Butterworth tiene una respuesta plana en la banda de paso y cae abruptamente en la banda de rechazo:

```
from scipy.signal import butter, filtfilt
import numpy as np

def filtro_paso_bajo(serie, fs_hz, fc_hz, orden=4):
    """
    Aplica filtro Butterworth de paso bajo.

    fs_hz : frecuencia de muestreo (Hz)
    fc_hz : frecuencia de corte (Hz)
    """
    nyq = fs_hz / 2
    wn = fc_hz / nyq # frecuencia de corte normalizada [0, 1]
    b, a = butter(orden, wn, btype='low')
    return filtfilt(b, a, serie) # filtfilt: sin desfase de fase

# Datos cada 10 min → fs = 1/600 Hz
fs = 1 / 600
```

```
# Cortar periodos menores a 2 horas →  $fc = 1/(2*3600)$  Hz
fc = 1 / (2 * 3600)

vel_filtrada = filtro_paso_bajo(df['velocidad'].dropna().values, fs, fc)
```

14.2.1 Filtro de paso alto (eliminar marea)

Para separar la corriente residual (sin marea) de la señal total:

```
def filtro_paso_alto(serie, fs_hz, fc_hz, orden=4):
    nyq = fs_hz / 2
    wn = fc_hz / nyq
    b, a = butter(orden, wn, btype='high')
    return filtfilt(b, a, serie)

# Eliminar componentes con período mayor a 30 horas
fc_alta = 1 / (30 * 3600)
vel_residual = filtro_paso_alto(df['velocidad'].dropna().values, fs, fc_alta)
```

14.2.2 Filtro de banda (aislar marea semidiurna)

```
def filtro_banda(serie, fs_hz, fc_low_hz, fc_high_hz, orden=4):
    nyq = fs_hz / 2
    wn = [fc_low_hz / nyq, fc_high_hz / nyq]
    b, a = butter(orden, wn, btype='band')
    return filtfilt(b, a, serie)

# Aislar M2: banda 11–14 horas de período
fc_low = 1 / (14 * 3600)
fc_high = 1 / (11 * 3600)
marea_M2 = filtro_banda(df['velocidad'].dropna().values, fs, fc_low, fc_high)
```

14.3 Interpolación de NaN

14.3.1 Interpolación lineal con pandas

```
# Interpolare NaN por interpolación lineal (por defecto)
df['vel_interp'] = df['velocidad'].interpolate(method='linear')

# Limitar la cantidad de NaN consecutivos a rellenar
df['vel_interp'] = df['velocidad'].interpolate(method='linear', limit=3)

# Interpolare también en los extremos (por defecto pandas no interpola bordes)
df['vel_interp'] = df['velocidad'].interpolate(method='linear',
                                              limit_direction='both')
```




Figura 5: Filtro Butterworth paso bajo — señal original vs filtrada

14.3.2 Interpolación cúbica con scipy

Para series con huecos pequeños donde se quiere una curva más suave:

```
from scipy.interpolate import interp1d

# Separar datos válidos de NaN
mascara_valida = df['velocidad'].notna()
t_valido = df.index[mascara_valida].astype(np.int64) # timestamps como enteros
v_valido = df['velocidad'][mascara_valida].values

# Construir interpolador
f_interp = interp1d(t_valido, v_valido, kind='cubic',
                    bounds_error=False, fill_value='extrapolate')

# Aplicar a todos los tiempos
t_todos = df.index.astype(np.int64)
df['vel_cubica'] = f_interp(t_todos)
```

14.4 Remuestreo temporal

14.4.1 Reducir resolución (downsampling)

```
# Datos cada 10 min → promedios horarios
df_horario = df.resample('1h').mean()

# Estadísticas adicionales al remuestrear
```

```
df_hora = df.resample('1h').agg({
    'velocidad': ['mean', 'max', 'std'],
    'direccion': 'mean'    # ojo: dirección requiere media circular
})
df_hora.columns = ['vel_media', 'vel_max', 'vel_std', 'dir_media']
```

14.4.2 Aumentar resolución (upsampling)

```
# Datos horarios → cada 10 minutos por interpolación lineal
df_10min = df_horario.resample('10min').interpolate(method='linear')
```

14.4.3 Alinear dos series con distinta resolución

```
# Serie A: cada 10 min    Serie B: cada 1 hora
# Remuestrear B a 10 min para comparar punto a punto
df_B_10min = df_B.resample('10min').interpolate(method='linear')

# Alinear por índice de tiempo (inner join)
df_conjunto = df_A.join(df_B_10min, how='inner', rsuffix='_B')
```

14.5 Detección y eliminación de spikes

Un filtro de desviación estándar elimina valores atípicos aislados:

```
def eliminar_spikes(serie, ventana=20, umbral_std=3.0):
    """
    Reemplaza por NaN los valores que se alejan más de umbral_std
    desviaciones estándar de la media móvil local.
    """
    media_local = serie.rolling(ventana, center=True, min_periods=5).mean()
    std_local = serie.rolling(ventana, center=True, min_periods=5).std()
    mascara_spike = np.abs(serie - media_local) > umbral_std * std_local
    serie_limpia = serie.copy()
    serie_limpia[mascara_spike] = np.nan
    n_spikes = mascara_spike.sum()
    print(f" Spikes eliminados: {n_spikes} ({n_spikes/len(serie)*100:.1f}%)")
    return serie_limpia

df['vel_limpia'] = eliminar_spikes(df['velocidad'])
```

14.6 Comparar señal original y filtrada

```
import matplotlib.pyplot as plt
import matplotlib.dates as mdates
```

```

fig, axes = plt.subplots(2, 1, figsize=(14, 7), sharex=True)

axes[0].plot(df.index, df['velocidad'], color='lightsteelblue',
             linewidth=0.5, label='Original')
axes[0].plot(df.index[mascara_valida], vel_filtrada, color='navy',
             linewidth=1.0, label='Filtrada (PB 2h)')
axes[0].set_ylabel('Velocidad (m/s)')
axes[0].legend()

axes[1].plot(df.index, df['velocidad'] - df['vel_suavizada'],
            color='firebrick', linewidth=0.5, label='Residuo (original - suavizada)')
axes[1].axhline(0, color='gray', linewidth=0.5)
axes[1].set_ylabel('Residuo (m/s)')
axes[1].legend()

axes[1].xaxis.set_major_formatter(mdates.DateFormatter('%d %b'))
fig.tight_layout()

```

► **filtfilt vs. lfilter** — `filtfilt` aplica el filtro dos veces (ida y vuelta) para cancelar el desfase de fase. Esto es importante en oceanografía: un desfase introduciría un error temporal en los picos de marea o corriente. Usar siempre `filtfilt` salvo que se necesite causalidad estricta.

□ **NaN antes de filtrar** — `butter` + `filtfilt` no toleran NaN en la serie. Siempre interpolar o eliminar los NaN antes de aplicar el filtro, y luego reponer los NaN en las posiciones originales si se quiere conservar la información de huecos.

15 python-docx

python-docx permite crear y modificar documentos Word (.docx) desde Python. Se usa para generar informes automáticamente: rellenar texto, insertar figuras, construir tablas y aplicar formato, todo a partir de una plantilla base.

15.1 Instalación

```
pip install python-docx
```

15.2 Estructura de un documento .docx

Un documento Word se organiza en **párrafos** (objetos Paragraph) que contienen **runs** (objetos Run). Cada run es un fragmento de texto con formato uniforme (fuente, negrita, tamaño, color). Entender esta jerarquía es clave para hacer reemplazos de texto sin perder el formato.

```
Document
├── paragraphs[]
│   └── runs[]    ← texto + formato
├── tables[]
│   └── rows[]
│       └── cells[]
│           └── paragraphs[]
│               └── runs[]
```

15.3 Abrir y guardar

```
from docx import Document

# Abrir plantilla existente
doc = Document('plantilla_informe.docx')

# Guardar con nuevo nombre (no sobrescribir la plantilla)
doc.save('informe_final.docx')
```

15.4 Leer contenido

```
# Todos los párrafos
for p in doc.paragraphs:
    if p.text.strip():
        print(repr(p.text[:80]))

# Texto completo de una tabla
for tabla in doc.tables:
    for fila in tabla.rows:
```

```
celdas = [c.text.strip() for c in fila.cells]
print(celdas)
```

15.5 Reemplazar texto en párrafos

El método más directo, pero que puede romper el formato si un placeholder está dividido entre runs:

```
def reemplazar_en_parrafo(parrafo, viejo, nuevo):
    """Reemplaza texto en el texto completo del párrafo preservando los runs."""
    if viejo in parrafo.text:
        for run in parrafo.runs:
            if viejo in run.text:
                run.text = run.text.replace(viejo, nuevo)
```

Para placeholders que pueden quedar divididos entre runs (problema común con autoformato de Word), usar reemplazo a nivel de XML:

```
import re

def reemplazar_en_parrafo_robusto(parrafo, viejo, nuevo):
    """Reconstruye el texto del párrafo si el placeholder está partido."""
    texto_completo = parrafo.text
    if viejo not in texto_completo:
        return

    # Vaciar todos los runs excepto el primero
    for i, run in enumerate(parrafo.runs):
        if i == 0:
            run.text = texto_completo.replace(viejo, nuevo)
        else:
            run.text = ''
```

15.6 Insertar figuras

```
from docx.shared import Cm

def insertar_figura_en_placeholder(doc, placeholder, ruta_imagen, ancho_cm=14):
    """Reemplaza un placeholder de texto por una imagen."""
    for parrafo in doc.paragraphs:
        if placeholder in parrafo.text:
            parrafo.clear()
            run = parrafo.add_run()
            run.add_picture(str(ruta_imagen), width=Cm(ancho_cm))
            return True
    return False
```



```

insertar_figura_en_placeholder(doc, '[FIGURA_ROSA]',
↪ 'figuras/rosa_corrientes_7m.png')

```

15.7 Construir tablas

```

from docx.shared import Pt, RGBColor
from docx.enum.text import WD_ALIGN_PARAGRAPH

def agregar_tabla_estadisticas(doc, df_stats, placeholder='[TABLA_STATS]'):
    """
    Inserta un DataFrame como tabla Word en la posición del placeholder.
    """
    for i, parrafo in enumerate(doc.paragraphs):
        if placeholder not in parrafo.text:
            continue

        parrafo.clear()

        # Crear tabla: 1 fila de encabezado + filas de datos
        ncols = len(df_stats.columns) + 1 # +1 para índice
        tabla = doc.add_table(rows=1, cols=ncols)
        tabla.style = 'Table Grid'

        # Encabezado
        fila_enc = tabla.rows[0]
        fila_enc.cells[0].text = df_stats.index.name or ''
        for j, col in enumerate(df_stats.columns):
            fila_enc.cells[j + 1].text = col

        # Datos
        for idx, fila_datos in df_stats.iterrows():
            fila = tabla.add_row()
            fila.cells[0].text = str(idx)
            for j, val in enumerate(fila_datos):
                fila.cells[j + 1].text = f'{val:.2f}' if isinstance(val, float) else
↪ str(val)

        # Mover tabla al lugar del párrafo
        parrafo._element.addnext(tabla._tbl)
        break

```

15.8 Aplicar formato a texto

```

from docx.shared import Pt, RGBColor
from docx.enum.text import WD_ALIGN_PARAGRAPH

# Agregar párrafo con formato
p = doc.add_paragraph()
run = p.add_run('Velocidad máxima registrada: ')
run.bold = True
run.font.size = Pt(11)

run2 = p.add_run('0.62 m/s')
run2.font.color.rgb = RGBColor(0x00, 0x5B, 0x96)
run2.bold = True

```

15.9 Iterar sobre cuerpo completo (párrafos + tablas)

Para aplicar reemplazos en todo el documento, incluyendo las celdas de las tablas:

```

def todos_los_parrafos(doc):
    """Generador que yields todos los párrafos del documento (cuerpo y tablas)."""
    yield from doc.paragraphs
    for tabla in doc.tables:
        for fila in tabla.rows:
            for celda in fila.cells:
                yield from celda.paragraphs

def reemplazar_en_doc(doc, reemplazos: dict):
    """
    Aplica un diccionario {placeholder: valor} en todo el documento.
    """
    for parrafo in todos_los_parrafos(doc):
        for viejo, nuevo in reemplazos.items():
            if viejo in parrafo.text:
                reemplazar_en_parrafo(parrafo, viejo, str(nuevo))

```

15.10 Flujo completo del autoinforme

```

from pathlib import Path

def generar_informe(ruta_plantilla, ruta_salida, reemplazos, figuras):
    """
    ruta_plantilla : Path a la plantilla .docx
    ruta_salida     : Path donde se guardará el informe
    reemplazos      : dict {placeholder_texto: valor}
    figuras         : dict {placeholder_figura: ruta_imagen}
    """
    doc = Document(ruta_plantilla)

```

```

# 1. Reemplazar texto
reemplazar_en_doc(doc, reemplazos)

# 2. Insertar figuras
for placeholder, ruta_img in figuras.items():
    ok = insertar_figura_en_placeholder(doc, placeholder, ruta_img)
    if not ok:
        print(f" ! Placeholder no encontrado: {placeholder}")

doc.save(ruta_salida)
print(f"Informe guardado: {ruta_salida}")

# Uso
generar_informe(
    ruta_plantilla = Path('plantillas/corrientes_v3.docx'),
    ruta_salida = Path('informes/Los_Vilos_Corrientes_2025.docx'),
    reemplazos = {
        '[PROYECTO]': 'Los Vilos – Campaña octubre 2025',
        '[VEL_MAX]': '0.62 m/s',
        '[DIR_PRED]': 'NNO (337°)',
        '[FECHA_INI]': '01/10/2025',
        '[FECHA_FIN]': '31/10/2025',
    },
    figuras = {
        '[FIGURA_ROSA]': 'figuras/rosa_corrientes_7m.png',
        '[FIGURA_SERIE]': 'figuras/serie_velocidad.png',
        '[FIGURA_HEATMAP]': 'figuras/heatmap_velocidad.png',
    }
)

```

□ **Estilos y plantilla** — Los estilos de Word (Título 1, Normal, Tabla Grid) están definidos en la plantilla. Si se crea un documento desde cero con Document(), los estilos por defecto de python-docx son distintos a los del template corporativo. Siempre trabajar sobre la plantilla para conservar los estilos visuales del informe.

16 Plantillas y placeholders

El autoinforme se basa en una plantilla Word preformateada (.docx) con marcadores de posición —**placeholders**— que Python reemplaza en tiempo de ejecución. Este enfoque separa el diseño visual (responsabilidad del Word) del contenido numérico (responsabilidad del script).

16.1 Convención de placeholders

Los placeholders se escriben en la plantilla entre corchetes, en mayúsculas y con guiones bajos:

[PROYECTO]	→ nombre del proyecto
[VEL_MAX_7M]	→ velocidad máxima en la capa de 7 m
[DIR_PRED_7M]	→ dirección predominante en 7 m
[FIGURA_ROSA_7M]	→ imagen de rosa de corrientes en 7 m
[TABLA_INCIDENCIA]	→ tabla de incidencia

► **Nomenclatura consistente** — Usar siempre el mismo formato en la plantilla y en el diccionario de reemplazos del script. Un error tipográfico en el placeholder deja el marcador sin reemplazar en el informe final, lo cual es fácil de detectar visualmente.

16.2 Validar que todos los placeholders se reemplazaron

Antes de guardar el informe, verificar que no quedó ningún placeholder sin llenar:

```
import re

def placeholders_pendientes(doc):
    """Retorna una lista de placeholders que no fueron reemplazados."""
    patron = re.compile(r'\[[A-Z_0-9]+\]')
    encontrados = set()
    for parrafo in todos_los_parrafos(doc):  # función del capítulo 14
        for match in patron.finditer(parrafo.text):
            encontrados.add(match.group())
    return sorted(encontrados)

pendientes = placeholders_pendientes(doc)
if pendientes:
    print(f" ! Placeholders sin reemplazar: {pendientes}")
else:
    print(" ✓ Todos los placeholders reemplazados")
```

16.3 Placeholders en tablas

Los placeholders pueden estar dentro de celdas de tablas. La función `todos_los_parrafos` del capítulo anterior ya los cubre, pero a veces se necesita reemplazar una celda completa:

```
def reemplazar_en_tablas(doc, reemplazos: dict):
    """Reemplaza placeholders dentro de todas las celdas de todas las tablas."""
    for tabla in doc.tables:
        for fila in tabla.rows:
            for celda in fila.cells:
                for parrafo in celda.paragraphs:
                    for viejo, nuevo in reemplazos.items():
                        if viejo in parrafo.text:
                            reemplazar_en_parrafo(parrafo, viejo, str(nuevo))
```

16.4 Placeholders que se repiten

Un mismo placeholder puede aparecer múltiples veces en el documento (p. ej. [PROYECTO] en el encabezado, en el cuerpo y en el pie de página). La función `reemplazar_en_doc` ya los reemplaza todos porque itera sobre todos los párrafos.

Para placeholders en **encabezados y pies de página**, hay que acceder explícitamente a las secciones:

```
def reemplazar_en_encabezados_pies(doc, reemplazos: dict):
    for seccion in doc.sections:
        for parrafo in seccion.header.paragraphs:
            for viejo, nuevo in reemplazos.items():
                if viejo in parrafo.text:
                    reemplazar_en_parrafo(parrafo, viejo, str(nuevo))
        for parrafo in seccion.footer.paragraphs:
            for viejo, nuevo in reemplazos.items():
                if viejo in parrafo.text:
                    reemplazar_en_parrafo(parrafo, viejo, str(nuevo))
```

16.5 Placeholder partido entre runs

Word a veces divide un placeholder en runs separados cuando el usuario activa la corrección automática o cuando lo escribe carácter a carácter. Por ejemplo [VEL_MAX] puede quedar como:

Run 1: "[VEL_"
Run 2: "MAX]"

En ese caso `viejo in parrafo.text` detecta el placeholder, pero `viejo in run.text` no encuentra nada. La solución es fusionar los runs antes de reemplazar:

```
def fusionar_runs_parrafo(parrafo):
    """Fusiona todos los runs del párrafo en el primero, preservando el formato del
    ↪ primero."""
    if not parrafo.runs:
        return
    texto_total = parrafo.text
    for i, run in enumerate(parrafo.runs):
```

```

        run.text = texto_total if i == 0 else ''

def reemplazar_robusto(doc, reemplazos: dict):
    """Fusiona runs y luego reemplaza. Usar solo cuando hay placeholders partidos."""
    patron = re.compile(r'\[[A-Z_0-9]+\]')
    for parrafo in todos_los_parrafos(doc):
        if patron.search(parrafo.text):
            fusionar_runs_parrafo(parrafo)
            for viejo, nuevo in reemplazos.items():
                if viejo in parrafo.text:
                    reemplazar_en_parrafo(parrafo, viejo, str(nuevo))

```

□ **Fusionar runs borra el formato interno** — Al fusionar todos los runs en uno solo, el texto queda con el formato del primer run (fuente, tamaño, negrita). Esto es aceptable si el placeholder ocupa su propio párrafo. Si el placeholder está en medio de un párrafo con texto mixto (parte en negrita, parte normal), la fusión puede romper el formato del párrafo completo.

16.6 Diccionario de reemplazos por campaña

En el pipeline se construye el diccionario de reemplazos a partir de los datos calculados:

```

def construir_reemplazos(df_stats, meta):
    """
    df_stats : DataFrame con estadísticas por profundidad
    meta      : dict con metadatos del proyecto (fechas, nombre, etc.)
    """
    reemplazos = {
        '[PROYECTO]': meta['nombre'],
        '[EMPRESA]': meta['empresa'],
        '[FECHA_INI]': meta['fecha_inicio'].strftime('%d/%m/%Y'),
        '[FECHA_FIN]': meta['fecha_fin'].strftime('%d/%m/%Y'),
        '[N_DATOS]': str(meta['n_datos']),
    }

    # Estadísticas por profundidad
    for prof in df_stats.index:
        fila = df_stats.loc[prof]
        clave = str(prof).replace('.', '_') # 7.5 → 7_5
        reemplazos[f'[VEL_MEDIA_{clave}M]'] = f"{fila['vel_media']:.2f}"
        reemplazos[f'[VEL_MAX_{clave}M]'] = f"{fila['vel_max']:.2f}"
        reemplazos[f'[DIR_PRED_{clave}M]'] = f"{fila['dir_pred']:.0f}°"

    return reemplazos

```

16.7 Flujo recomendado

```
from pathlib import Path
from docx import Document

def generar_informe_completo(ruta_plantilla, ruta_salida, meta, df_stats, figuras):
    doc = Document(ruta_plantilla)

    # 1. Reemplazar texto en cuerpo
    reemplazos = construir_reemplazos(df_stats, meta)
    reemplazar_robusto(doc, reemplazos)

    # 2. Reemplazar en encabezados y pies
    reemplazar_en_encabezados_pies(doc, reemplazos)

    # 3. Insertar figuras
    for placeholder, ruta_img in figuras.items():
        insertar_figura_en_placeholder(doc, placeholder, ruta_img)

    # 4. Validar
    pendientes = placeholders_pendientes(doc)
    if pendientes:
        print(f" ! Sin reemplazar: {pendientes}")

    doc.save(ruta_salida)
    print(f"Informe generado: {ruta_salida.name}")
```

17 Importación dinámica

El autoinforme es un script genérico que puede procesar cualquier campaña. La configuración específica de cada proyecto (rutas, parámetros, profundidades, nombre de empresa) vive en un módulo Python separado que se carga en tiempo de ejecución según el nombre del proyecto. Esto elimina la necesidad de editar el script central cada vez que se agrega una nueva campaña.

17.1 El problema: configuración por proyecto

Sin importación dinámica, el script tendría bloques if/elif:

```
# MAL: requiere modificar el script central para cada proyecto
if proyecto == 'los_vilos':
    from configs import los_vilos as cfg
elif proyecto == 'coquimbo':
    from configs import coquimbo as cfg
elif proyecto == 'iquique':
    from configs import iquique as cfg
# ... y así indefinidamente
```

Con importación dinámica, el script central no cambia nunca:

```
# BIEN: el script carga automáticamente el módulo correcto
import importlib
cfg = importlib.import_module(f'configs.{nombre_proyecto}')
```

17.2 importlib.import_module

```
import importlib

def cargar_config(nombre_proyecto):
    """
    Carga el módulo de configuración para el proyecto indicado.
    Lanza ImportError con mensaje claro si no existe.
    """
    nombre_modulo = f'configs.{nombre_proyecto}'
    try:
        modulo = importlib.import_module(nombre_modulo)
    except ModuleNotFoundError:
        raise FileNotFoundError(
            f"No existe configuración para '{nombre_proyecto}'. "
            f"Crear el archivo configs/{nombre_proyecto}.py"
        )
    return modulo

# Uso
```



```

cfg = cargar_config('los_vilos_oct2025')

ruta_datos = cfg.RUTA_DATOS
profundidades = cfg.PROFUNDIDADES
empresa = cfg.EMPRESA

```

17.3 Estructura de un módulo de configuración

Cada proyecto tiene un archivo en configs/:

```

autoinforme/
  configs/
    __init__.py      ← vacío, hace de configs un paquete
    los_vilos_oct2025.py
    coquimbo_mar2025.py
    iquique_ene2026.py
  autoinforme.py     ← script central (nunca se modifica)

```

Un módulo de configuración típico:

```

# configs/los_vilos_oct2025.py
from pathlib import Path

PROYECTO      = 'Los Vilos – Campaña octubre 2025'
EMPRESA       = 'Puerto Los Vilos S.A.'
FECHA_INICIO  = '2025-10-01'
FECHA_FIN     = '2025-10-31'

RUTA_BASE     = Path('/mnt/c/Users/Tomas/PELICANOS Dropbox/Proyectos2025/Los Vilos')
RUTA_DATOS    = RUTA_BASE / 'datos' / 'corrientes_procesadas.xlsx'
RUTA_FIGURAS  = RUTA_BASE / 'figuras_magnitud'
RUTA_SALIDA   = RUTA_BASE / 'informe' / 'Los_Vilos_Corrientes_Oct2025.docx'
PLANTILLA     = Path('plantillas') / 'corrientes_v3.docx'

PROFUNDIDADES = [3, 5, 7, 9, 11, 13, 15]
BINS_VEL      = [0, 0.05, 0.1, 0.2, float('inf')]

```

17.4 Verificar que el módulo tiene los atributos necesarios

```

ATRIBUTOS_REQUERIDOS = [
    'PROYECTO', 'EMPRESA', 'FECHA_INICIO', 'FECHA_FIN',
    'RUTA_DATOS', 'RUTA_FIGURAS', 'RUTA_SALIDA', 'PLANTILLA',
    'PROFUNDIDADES',
]

def validar_config(cfg, nombre_proyecto):
    faltantes = [attr for attr in ATRIBUTOS_REQUERIDOS if not hasattr(cfg, attr)]

```

```

if faltantes:
    raise AttributeError(
        f"Configuración '{nombre_proyecto}' incompleta. "
        f"Faltan: {faltantes}"
    )

```

17.5 Recargar un módulo modificado

Durante el desarrollo, si se edita el archivo de configuración con el script ya corriendo en Spyder, hay que recargar el módulo para ver los cambios:

```

import importlib

cfg = importlib.import_module('configs.los_vilos_oct2025')

# Después de editar el archivo:
importlib.reload(cfg)

```

17.6 Listar proyectos disponibles

```

from pathlib import Path

def listar_proyectos(carpeta_configs='configs'):
    carpeta = Path(carpeta_configs)
    proyectos = [
        p.stem for p in carpeta.glob('*.py')
        if p.stem != '__init__'
    ]
    return sorted(proyectos)

print("Proyectos disponibles:")
for p in listar_proyectos():
    print(f" {p}")

```

17.7 Patrón del script central

El script autoinforme.py recibe el nombre del proyecto por argumento de línea de comandos o por input interactivo:

```

import sys
import importlib

def main():
    if len(sys.argv) > 1:
        nombre_proyecto = sys.argv[1]
    else:

```

```

proyectos = listar_proyectos()
print("Proyectos disponibles:")
for i, p in enumerate(proyectos):
    print(f"  [{i}] {p}")
idx = int(input("Seleccionar: "))
nombre_proyecto = proyectos[idx]

cfg = cargar_config(nombre_proyecto)
validar_config(cfg, nombre_proyecto)

print(f"\nProcesando: {cfg.PROYECTO}")

# El resto del pipeline usa cfg.RUTA_DATOS, cfg.PROFUNDIDADES, etc.
datos = cargar_datos(cfg.RUTA_DATOS)
stats = calcular_estadisticas(datos, cfg.PROFUNDIDADES)
generar_figuras(datos, stats, cfg.RUTA_FIGURAS)
generar_informe(cfg.PLANTILLA, cfg.RUTA_SALIDA, cfg, stats)

if __name__ == '__main__':
    main()

```

► **Alternativa con JSON** — Si la configuración es puramente datos (sin paths que necesiten Path o expresiones Python), se puede guardar como JSON y cargar con `json.load`. La ventaja de módulos `.py` es que permiten expresiones, herencia entre configs y paths relativos calculados con `Path(file).parent`.

18 Rasterio y GeoPandas

En el contexto oceanográfico, los datos geoespaciales aparecen en dos formas: **rasters** (grillas de valores, como batimetría, temperatura SST o campos de viento en grilla) y **vectores** (puntos, líneas y polígonos, como estaciones de medición, líneas de costa o polígonos de áreas de estudio). rasterio maneja rasters; geopandas maneja vectores.

18.1 Instalación

```
pip install rasterio geopandas
```

18.2 Leer un raster con rasterio

Un raster GeoTIFF contiene una o varias bandas de valores sobre una grilla georreferenciada:

```
import rasterio
import numpy as np

with rasterio.open('batimetria_zona.tif') as src:
    # Metadatos
    print(f"CRS: {src.crs}")          # sistema de coordenadas
    print(f"Dimensiones: {src.width} x {src.height}")
    print(f"Bandas: {src.count}")
    print(f"Bounding box: {src.bounds}")
    print(f"Resolución: {src.res}")    # (dx, dy) en unidades del CRS

    # Leer banda 1
    datos = src.read(1).astype(float)    # array 2D (filas x columnas)
    datos[datos == src.nodata] = np.nan    # convertir nodata a NaN

    # Coordenadas del centroide de cada celda
    transform = src.transform
```

18.3 Obtener coordenadas de la grilla

```
import rasterio
from rasterio.transform import xy

with rasterio.open('batimetria_zona.tif') as src:
    datos = src.read(1).astype(float)
    filas, cols = np.indices(datos.shape)
    lons, lats = xy(src.transform, filas, cols)
    lons = np.array(lons)
    lats = np.array(lats)
```

18.4 Extraer el valor en un punto

Para extraer el valor del raster en una coordenada (lat, lon):

```
from rasterio.sample import sample_gen

def extraer_valor(raster_path, lon, lat):
    """Extrae el valor del raster en el punto (lon, lat)."""
    with rasterio.open(raster_path) as src:
        valores = list(src.sample([(lon, lat)]))
    return valores[0][0]

# Profundidad en la ubicación de una estación
prof = extraer_valor('batimetria.tif', lon=-71.52, lat=-29.90)
print(f"Profundidad: {prof:.1f} m")
```

18.5 Leer un shapefile con GeoPandas

```
import geopandas as gpd

# Línea de costa de Chile
costa = gpd.read_file('costa_chile.shp')
print(costa.crs)
print(costa.head())

# Filtrar por atributo
costa_4ta = costa[costa['region'] == 'Coquimbo']
```

18.6 Crear un GeoDataFrame desde coordenadas

```
import pandas as pd
import geopandas as gpd
from shapely.geometry import Point

# Estaciones de medición
estaciones = pd.DataFrame({
    'nombre': ['Los Vilos', 'Coquimbo', 'La Serena'],
    'lon':     [-71.52,      -71.35,      -71.25],
    'lat':     [-31.90,      -29.96,      -29.91],
    'vel_media': [0.12, 0.09, 0.14]
})

gdf_estaciones = gpd.GeoDataFrame(
    estaciones,
    geometry=gpd.points_from_xy(estaciones.lon, estaciones.lat),
    crs='EPSG:4326' # WGS84 geográfico
```

```
)
```

18.7 Reproyectar

```
# De WGS84 (EPSG:4326) a UTM zona 19S (EPSG:32719)
gdf_utm = gdf_estaciones.to_crs('EPSG:32719')
print(gdf_utm.geometry[0]) # coordenadas en metros
```

18.8 Operaciones espaciales básicas

```
# Buffer de 5 km alrededor de cada estación
gdf_buffer = gdf_utm.copy()
gdf_buffer['geometry'] = gdf_utm.geometry.buffer(5000) # metros

# Intersección: estaciones dentro de un polígono de estudio
area_estudio = gpd.read_file('area_estudio.shp').to_crs('EPSG:32719')
estaciones_en_area = gpd.sjoin(gdf_utm, area_estudio, how='inner',
    ↪ predicate='within')

# Distancia más cercana entre puntos y costa
gdf_utm['dist_costa_m'] = gdf_utm.geometry.apply(
    lambda p: costa.to_crs('EPSG:32719').distance(p).min()
)
```

18.9 Exportar resultados

```
# Guardar como shapefile
gdf_estaciones.to_file('estaciones_resultado.shp')

# Guardar como GeoJSON (más portable, sin limitación de nombre de columna)
gdf_estaciones.to_file('estaciones_resultado.geojson', driver='GeoJSON')

# Guardar raster modificado
with rasterio.open('batimetria.tif') as src:
    meta = src.meta.copy()
    datos = src.read(1).astype(float)

datos_suavizado = datos.copy() # ... algún procesamiento

meta.update(dtype='float32')
with rasterio.open('batimetria_suavizada.tif', 'w', **meta) as dst:
    dst.write(datos_suavizado.astype('float32'), 1)
```

18.10 Estadísticas zonales

Calcular estadísticas del raster dentro de cada polígono:

```
from rasterstats import zonal_stats

# Profundidad media dentro de cada área de estudio
stats = zonal_stats(
    'areas_estudio.shp',
    'batimetria.tif',
    stats=['mean', 'min', 'max', 'std'],
    nodata=-9999
)

for area, s in zip(areas_estudio.itertuples(), stats):
    print(f"{area.nombre}: prof_media = {s['mean']:.1f} m")
```

► **Sistema de coordenadas** — Antes de cualquier operación espacial (buffer, distancias, áreas), reprojectar todos los datos a un CRS métrico como UTM. Los cálculos de distancia en grados (WGS84) son incorrectos y varían con la latitud. Para Chile central usar EPSG:32719 (UTM zona 19 Sur).

□ **Archivos shapefile** — Un shapefile en realidad son varios archivos (.shp, .shx, .dbf, .prj). Al copiar o mover shapefiles, mover todos los archivos con el mismo nombre base. La alternativa moderna y más portable es GeoPackage (.gpkg) o GeoJSON.

19 Coordenadas y mapas

La visualización geoespacial en el pipeline incluye dos tareas: convertir coordenadas entre sistemas de referencia (UTM ↔ geográfico) y generar mapas de contexto para el informe. Los mapas sitúan la zona de estudio, marcan las estaciones y muestran resultados con color codificado por variable.

19.1 Conversión UTM ↔ lat/lon con pyproj

```
from pyproj import Transformer

# Definir transformador WGS84 ↔ UTM 19S
wgs84_a_utm = Transformer.from_crs('EPSG:4326', 'EPSG:32719', always_xy=True)
utm_a_wgs84 = Transformer.from_crs('EPSG:32719', 'EPSG:4326', always_xy=True)

# Convertir un punto geográfico a UTM
lon, lat = -71.52, -31.90
este, norte = wgs84_a_utm.transform(lon, lat)
print(f"Este: {este:.1f} m, Norte: {norte:.1f} m")

# Convertir de vuelta
lon2, lat2 = utm_a_wgs84.transform(este, norte)
print(f"Lon: {lon2:.6f}°, Lat: {lat2:.6f}°")
```

19.1.1 Convertir un DataFrame de coordenadas

```
import pandas as pd
from pyproj import Transformer

def utm_a_geo(df, col_este='Este', col_norte='Norte', zona_utm='EPSG:32719'):
    """Agrega columnas Lon y Lat a un DataFrame con coordenadas UTM."""
    t = Transformer.from_crs(zona_utm, 'EPSG:4326', always_xy=True)
    lons, lats = t.transform(df[col_este].values, df[col_norte].values)
    df = df.copy()
    df['Lon'] = lons
    df['Lat'] = lats
    return df

df_estaciones = utm_a_geo(df_estaciones)
```

19.2 Mapa de contexto con GeoPandas y Matplotlib

```
import geopandas as gpd
import matplotlib.pyplot as plt
import matplotlib.cm as cm
```



```

import matplotlib.colors as mcolors
import numpy as np

def mapa_estaciones(gdf_estaciones, col_valor, titulo='',
                    ruta_costa='costa_chile.shp', ruta_salida=None):
    """
    Genera un mapa con la línea de costa y las estaciones
    coloreadas por col_valor.
    """
    costa = gpd.read_file(ruta_costa)

    fig, ax = plt.subplots(figsize=(8, 10))

    # Línea de costa
    costa.plot(ax=ax, color='darkgreen', linewidth=0.5, alpha=0.7)

    # Estaciones coloreadas por el valor de interés
    vmin = gdf_estaciones[col_valor].min()
    vmax = gdf_estaciones[col_valor].max()
    norm = mcolors.Normalize(vmin=vmin, vmax=vmax)
    cmap = cm.YlOrRd

    sc = ax.scatter(
        gdf_estaciones.geometry.x,
        gdf_estaciones.geometry.y,
        c=gdf_estaciones[col_valor],
        cmap=cmap, norm=norm,
        s=80, zorder=5, edgecolors='black', linewidths=0.5
    )

    # Etiquetas de estación
    for _, row in gdf_estaciones.iterrows():
        ax.annotate(
            row['nombre'],
            xy=(row.geometry.x, row.geometry.y),
            xytext=(5, 5), textcoords='offset points',
            fontsize=8
        )

    plt.colorbar(sc, ax=ax, label=col_valor, shrink=0.6)

    ax.set_xlabel('Longitud (°)')
    ax.set_ylabel('Latitud (°)')
    ax.set_title(titulo)
    ax.grid(True, linestyle='--', alpha=0.4)
    fig.tight_layout()

```

```

if ruta_salida:
    fig.savefig(ruta_salida, dpi=150, bbox_inches='tight')
    plt.close(fig)

return fig, ax

```

19.3 Mapa de fondo con contextily (imágenes de satélite/OpenStreetMap)

```

import contextily as ctx

fig, ax = plt.subplots(figsize=(9, 9))

# Graficar estaciones (en WebMercator EPSG:3857)
gdf_web = gdf_estaciones.to_crs('EPSG:3857')
gdf_web.plot(ax=ax, color='red', markersize=60, zorder=4)

# Agregar mapa base desde internet
ctx.add_basemap(ax, source=ctx.providers.CartoDB.Positron, zoom=10)

ax.set_axis_off()
ax.set_title('Zona de estudio')

```

□ **contextily requiere internet** — contextily descarga las teselas del mapa desde servidores externos. En equipos sin conexión usar el shapefile de costa en su lugar.

19.4 Grilla de campo vectorial (corrientes)

Para visualizar un campo de corrientes interpolado en una grilla:

```

from scipy.interpolate import griddata

# Puntos de medición dispersos
lons = gdf_estaciones.geometry.x.values
lats = gdf_estaciones.geometry.y.values
u_vals = gdf_estaciones['u_medio'].values # componente E-O
v_vals = gdf_estaciones['v_medio'].values # componente N-S

# Grilla regular de interpolación
lon_grid = np.linspace(lons.min() - 0.1, lons.max() + 0.1, 30)
lat_grid = np.linspace(lats.min() - 0.1, lats.max() + 0.1, 30)
LON, LAT = np.meshgrid(lon_grid, lat_grid)

U = griddata((lons, lats), u_vals, (LON, LAT), method='linear')
V = griddata((lons, lats), v_vals, (LON, LAT), method='linear')

fig, ax = plt.subplots(figsize=(9, 9))
ax.quiver(LON, LAT, U, V, np.sqrt(U**2 + V**2),

```

```

        cmap='YlOrRd', scale=5, width=0.003, alpha=0.8)
ax.scatter(lons, lats, c='black', s=20, zorder=5)
ax.set_xlabel('Longitud (°)')
ax.set_ylabel('Latitud (°)')
ax.set_title('Campo de corriente media superficial')
ax.set_aspect('equal')

```

19.5 Recortar raster a área de estudio

```

import rasterio
from rasterio.mask import mask
import geopandas as gpd
from shapely.geometry import mapping

area = gpd.read_file('area_estudio.shp').to_crs('EPSG:4326')

with rasterio.open('batimetria_nacional.tif') as src:
    out_image, out_transform = mask(
        src,
        [mapping(geom) for geom in area.geometry],
        crop=True,
        nodata=np.nan
    )
    out_meta = src.meta.copy()

out_meta.update({
    'driver': 'GTiff',
    'height': out_image.shape[1],
    'width': out_image.shape[2],
    'transform': out_transform
})

with rasterio.open('batimetria_zona.tif', 'w', **out_meta) as dst:
    dst.write(out_image)

```

19.6 Calcular distancia a la costa

```

from pyproj import Geod

geod = Geod(ellps='WGS84')

def distancia_a_la_costa_km(lon_estacion, lat_estacion, gdf_costa):
    """
    Calcula la distancia mínima en km de un punto a la línea de costa.
    """

```

```

gdf_utm = gdf_costa.to_crs('EPSG:32719')
from shapely.geometry import Point
punto_utm = gpd.GeoDataFrame(geometry=[Point(lon_estacion, lat_estacion)],
                                crs='EPSG:4326').to_crs('EPSG:32719').geometry[0]
dist_m = gdf_utm.geometry.distance(punto_utm).min()
return dist_m / 1000

for _, row in gdf_estaciones.iterrows():
    d = distancia_a_la_costa_km(row.geometry.x, row.geometry.y, costa)
    print(f"{row['nombre']}: {d:.1f} km de la costa")

```

► **Selección del sistema de coordenadas** — Para Chile, UTM zona 19 Sur (EPSG:32719) cubre desde 66°O hasta 60°O, incluyendo toda la costa continental. La zona 18 Sur (EPSG:32718) cubre desde 72°O hasta 66°O y es necesaria para el extremo sur y la región de Los Lagos. Verificar siempre que los datos de entrada estén en el CRS correcto antes de operar.

20 OCR de cartas batimétricas

Las cartas batimétricas —tanto cartas náuticas escaneadas (SHOA) como mosaicos de cartografía digital (Navionics)— contienen cientos de sondeos de profundidad representados como números dispersos sobre la imagen. Digitalizarlos manualmente implica hacer clic en cada número y escribir el valor. Con OpenCV y Tesseract el proceso se automatiza: Python detecta los números, los lee y los georeferencia en minutos.

20.1 Dependencias

```
pip install opencv-python pytesseract pillow rasterio
# Tesseract (Windows): https://github.com/UB-Mannheim/tesseract/wiki
# Linux/WSL: sudo apt install tesseract-ocr
```

20.2 Flujo general del pipeline

```
imagen (JPG/TIFF/GeoTIFF)
    ↓ preprocesamiento (umbralización, máscara de tierra)
    ↓ detección de regiones candidatas (contornos)
    ↓ Tesseract OCR sobre cada región
    ↓ filtro de valores plausibles
    ↓ georeferencia (GCP lineal o GeoTIFF)
    ↓ exportar CSV / XYZ
```

20.3 Cargar y preprocesar la imagen

```
import cv2
import numpy as np

# cv2.imdecode con fromfile maneja rutas con tildes y espacios en Windows
img_bgr = cv2.imdecode(np.fromfile('carta_shoa.tiff', dtype=np.uint8),
    ↪ cv2.IMREAD_COLOR)
img_gray = cv2.cvtColor(img_bgr, cv2.COLOR_BGR2GRAY)
img_rgb = cv2.cvtColor(img_bgr, cv2.COLOR_BGR2RGB)

h_px, w_px = img_gray.shape
print(f'Imagen: {w_px} × {h_px} px')
```

20.3.1 Umbralización adaptativa (cartas B&N — SHOA)

Las cartas SHOA son blanco y negro con gradientes de iluminación. La umbralización adaptativa compensa variaciones de brillo locales:

```
# Binarizar: texto negro sobre fondo blanco
img_bin = cv2.adaptiveThreshold(
```

```

img_gray, 255,
cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
cv2.THRESH_BINARY,
blockSize=15,    # tamaño del vecindario local
C=5              # constante restada a la media local
)

# Escalar × 3 para que Tesseract trabaje con números más grandes
ESCALA = 3
img_up = cv2.resize(img_bin, None, fx=ESCALA, fy=ESCALA,
                    interpolation=cv2.INTER_CUBIC)

```

20.3.2 Máscara de tierra por color HSV (cartas Navionics)

Las cartas Navionics usan color: tierra = amarillo/verde, agua = azul. Enmascarar la tierra evita que OCR confunda textos de topografía con sondeos marinos:

```

img_hsv = cv2.cvtColor(img_bgr, cv2.COLOR_BGR2HSV)
H, S = img_hsv[:, :, 0], img_hsv[:, :, 1]

# Rangos en OpenCV: H está en [0, 179] (la mitad del ángulo estándar)
mask_tierra = (
    ((H >= 10) & (H <= 24) & (S > 45)) |    # amarillo tierra
    ((H >= 33) & (H <= 60) & (S > 35))      # verde intermareal
)

# Dilatar 2 iteraciones para cubrir bordes y píxeles de borde
kernel = np.ones((5, 5), np.uint8)
mask_tierra = cv2.dilate(mask_tierra.astype(np.uint8), kernel,
    ↪ iterations=2).astype(bool)

# Píxeles oscuros en zona de agua = candidatos a texto
UMBRAL_GRIS = 80
mask_texto = (img_gray < UMBRAL_GRIS) & (~mask_tierra)
mask_u8 = mask_texto.astype(np.uint8) * 255

# Eliminar ruido de compresión JPEG
mask_u8 = cv2.morphologyEx(mask_u8, cv2.MORPH_OPEN, np.ones((2, 2), np.uint8))

```

20.4 Detectar regiones candidatas

Cada número es un grupo de píxeles conectados. La dilatación horizontal conecta dígitos del mismo número antes de buscar contornos:

```

# Conectar dígitos del mismo número horizontalmente
ANCHO_MAX_PX = 90    # hasta 4 dígitos
kw = max(6, int(ANCHO_MAX_PX * 0.55))

```

```

kernel_h = cv2.getStructuringElement(cv2.MORPH_RECT, (kw, 1))
mask_groups = cv2.dilate(mask_u8, kernel_h)

contours, _ = cv2.findContours(mask_groups, cv2.RETR_EXTERNAL,
    ↪ cv2.CHAIN_APPROX_SIMPLE)

# Filtrar por tamaño esperado de un número (ajustar según zoom)
ALTO_MIN, ALTO_MAX = 6, 28
ANCHO_MIN, ANCHO_MAX = 4, 90

candidatos = []
for cnt in contours:
    x, y, w, h = cv2.boundingRect(cnt)
    if not (ALTO_MIN <= h <= ALTO_MAX and ANCHO_MIN <= w <= ANCHO_MAX):
        continue
    # Densidad mínima de píxeles oscuros (descartar cajas vacías)
    if mask_u8[y:y+h, x:x+w].mean() < 8:
        continue
    candidatos.append((x, y, w, h))

print(f'Candidatos a número: {len(candidatos)}')

```

20.5 OCR con Tesseract

```

import pytesseract
import re

# Windows: ajustar ruta al ejecutable de Tesseract
pytesseract.pytesseract.tesseract_cmd = r'C:\Program
    ↪ Files\Tesseract-OCR\tesseract.exe'

# Configuración: modo página 8 (un solo bloque de texto), solo dígitos y punto
config_tess = '--psm 8 --oem 3 -c tesseract_char_whitelist=0123456789.'
pat_num = re.compile(r'^\d{1,4}(\.\d{1,2})?$',)

PROF_MIN, PROF_MAX = 0.5, 9999.0
CONF_MINIMA = 45
ESCALA_OCR = 4 # ampliar imagen para OCR
PAD = 5 # píxeles de margen alrededor del candidato

puntos_ocr = []

# Imagen binaria fondo blanco / texto negro para Tesseract
img_bin_ocr = np.where(mask_u8[:, :, np.newaxis] > 0,
    np.zeros_like(img_rgb),
    np.full_like(img_rgb, 255)).astype(np.uint8)

```

```

for x, y, w, h in candidatos:
    # Recortar con margen
    x1, y1 = max(0, x - PAD), max(0, y - PAD)
    x2, y2 = min(w_px, x+w+PAD), min(h_px, y+h+PAD)
    roi = img_bin_ocr[y1:y2, x1:x2]

    # Ampliar para OCR
    roi_up = cv2.resize(roi, None, fx=ESCALA_OCR, fy=ESCALA_OCR,
                        interpolation=cv2.INTER_NEAREST)

    datos = pytesseract.image_to_data(roi_up, config=config_tess,
                                      output_type=pytesseract.Output.DICT)

    for j, txt in enumerate(datos['text']):
        txt = str(txt).strip()
        if not pat_num.match(txt):
            continue
        try:
            val = float(txt)
        except ValueError:
            continue
        if not (PROF_MIN <= val <= PROF_MAX):
            continue
        if int(datos['conf'][j]) < CONF_MINIMA:
            continue

        # Centro del bbox en coordenadas de imagen original
        puntos_ocr.append({
            'col': x + w / 2.0,
            'row': y + h / 2.0,
            'depth_m': val,
            'conf': int(datos['conf'][j])
        })
        break # un número por región

print(f'Sondeos detectados: {len(puntos_ocr)}')

```

20.5.1 Modos PSM de Tesseract

PSM	Cuándo usar
8	Una sola palabra/número por recorte (recomendado para candidatos ya recortados)
11	Texto disperso sobre toda la imagen (útil para OCR sobre imagen completa)
6	Un bloque de texto uniforme

20.6 Deduplicar sondeos solapados

```
# Conservar el de mayor confianza entre puntos a menos de 15 px de distancia
pts = sorted(puntos_ocr, key=lambda p: -p['conf'])
pts_unicos = []
for p in pts:
    if all(np.hypot(p['row'] - u['row'], p['col'] - u['col']) > 15
            for u in pts_unicos):
        pts_unicos.append(p)

print(f'Tras deduplicar: {len(pts_unicos)} sondeos únicos')
```

20.7 Georeferencia

20.7.1 Opción A — GeoTIFF (automática con rasterio)

Si la imagen ya viene georeferenciada (p. ej. GeoTIFF con EPSG:4326):

```
import rasterio
from rasterio.transform import xy as rxy

with rasterio.open('navionics_area.tif') as src:
    tf = src.transform

def px_a_geo(col, row):
    lon, lat = rxy(tf, row, col)
    return float(lon), float(lat)
```

20.7.2 Opción B — GCPs manuales (cartas escaneadas SHOA)

Cuando la imagen no tiene georeferencia embebida, se usan puntos de control (GCPs): pares (fila_px, col_px) → (lon, lat) de referencias conocidas en la carta:

```
import numpy as np

# GCPs: (fila_px, col_px, lon, lat)
GCPS = [
    ( 100,  200, -72.600, -41.500), # esquina superior izquierda
    ( 100, 3800, -71.900, -41.500), # esquina superior derecha
    (2900,  200, -72.600, -42.200), # esquina inferior izquierda
    (2900, 3800, -71.900, -42.200), # esquina inferior derecha
]

gcps = np.array(GCPS, dtype=float)
```

```

A      = np.column_stack([gcps[:, 1], gcps[:, 0], np.ones(len(gcps))])

coef_lon, _, _, _ = np.linalg.lstsq(A, gcps[:, 2], rcond=None)
coef_lat, _, _, _ = np.linalg.lstsq(A, gcps[:, 3], rcond=None)

def px_a_geo(col, row):
    v = np.array([col, row, 1.0])
    return float(coef_lon @ v), float(coef_lat @ v)

# Verificar error en los propios GCPs
for fila, col, lon_r, lat_r in GCPS:
    lon_e, lat_e = px_a_geo(col, fila)
    err_m = np.hypot((lon_e - lon_r) * 111000, (lat_e - lat_r) * 111000)
    print(f' Error en GCP: {err_m:.0f} m')

```

► **Precisión con GCPs** — Con 4 GCPs en las esquinas el error típico es 50-150 m. Agregar referencias internas de la retícula (intersecciones de meridianos y paralelos impresos en la carta) baja el error a 10-30 m. Con 8+ GCPs bien distribuidos la transformación lineal converge a la precisión de escaneo.

20.8 Exportar a CSV y XYZ

```

import pandas as pd

registros = []
for p in pts_unicos:
    lon, lat = px_a_geo(p['col'], p['row'])
    registros.append({'lon': lon, 'lat': lat, 'depth_m': p['depth_m']})

df = pd.DataFrame(registros).sort_values('depth_m').reset_index(drop=True)

# CSV para QGIS
df.to_csv('batimetria.csv', index=False, float_format='%.6f')

# XYZ (lon lat profundidad) para Blue Kenue / SWAN
df[['lon', 'lat', 'depth_m']].to_csv(
    'batimetria.xyz', sep=' ', index=False, header=False, float_format='%.6f')

print(f'Exportados: {len(df)} sondeos')
print(f'Rango: {df["depth_m"].min():.1f} – {df["depth_m"].max():.1f} m')

```

20.9 Visualizar resultado

```

import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(9, 7))

```

```

sc = ax.scatter(df['lon'], df['lat'],
                c=df['depth_m'], cmap='Blues_r',
                s=15, edgecolors='k', linewidths=0.2, vmin=0)
plt.colorbar(sc, ax=ax, label='Profundidad (m)')
ax.set_xlabel('Longitud (°)')
ax.set_ylabel('Latitud (°)')
ax.set_title(f'Batimetría digitalizada — {len(df)} puntos')
ax.set_aspect('equal')
plt.tight_layout()
plt.savefig('batimetria_mapa.png', dpi=150, bbox_inches='tight')
plt.show()

```

□ **Unidades en cartas SHOA** — Las cartas SHOA antiguas pueden estar en pies o brazas, no en metros. Verificar en el margen de la carta. Para convertir: 1 pie = 0.3048 m, 1 braza = 1.8288 m.

► **Guardar sesión para no repetir OCR** — El OCR sobre una imagen grande puede tardar varios minutos. Guardar los resultados en JSON permite retomarlos sin reprocesar: `python import json with open('sesion.json', 'w') as f: json.dump(pts_unicos, f) # Cargar al reiniciar: # with open('sesion.json') as f: pts_unicos = json.load(f)`

21 Outputs de CROCO-ROMS

CROCO (Coastal and Regional Ocean COmmunity model) es un modelo oceánico regional que simula temperatura, salinidad y corrientes en un dominio definido por el usuario. Sus archivos de salida están en formato **NetCDF4**: un estándar científico para almacenar datos multidimensionales con coordenadas etiquetadas (tiempo, profundidad, latitud, longitud).

La herramienta estándar para trabajar con estos archivos en Python es **xarray**, que carga los datos de forma diferida: lee la estructura del archivo sin traer todos los valores a memoria, y accede a ellos solo cuando se necesitan.

21.1 Instalación

```
pip install xarray netcdf4 matplotlib cartopy scipy
```

21.2 Abrir un archivo y explorar su estructura

```
import xarray as xr

ds = xr.open_dataset('croco_his.nc')
print(ds)
```

La salida muestra dimensiones, variables y atributos globales:

Dimensions: (ocean_time: 365, s_rho: 20, eta_rho: 150, xi_rho: 200)

Data variables:

temp	(ocean_time, s_rho, eta_rho, xi_rho)	float32
salt	(ocean_time, s_rho, eta_rho, xi_rho)	float32
u	(ocean_time, s_rho, eta_u, xi_u)	float32
v	(ocean_time, s_rho, eta_v, xi_v)	float32
zeta	(ocean_time, eta_rho, xi_rho)	float32
lon_rho	(eta_rho, xi_rho)	float64
lat_rho	(eta_rho, xi_rho)	float64
h	(eta_rho, xi_rho)	float64

Variable	Descripción
temp	Temperatura potencial (°C)
salt	Salinidad (PSU)
u, v	Corrientes E-O y N-S (m/s) en grillas desplazadas
zeta	Elevación de la superficie libre (m)
h	Batimetría — profundidad del fondo (m)
lon_rho, lat_rho	Coordenadas de cada celda de la grilla (2D)

21.3 Coordenadas verticales sigma

CROCO no usa profundidades fijas: usa **coordenadas sigma** (σ), que siguen la forma del fondo oceánico. En superficie $\sigma = 0$ y en el fondo $\sigma = -1$. Los N niveles se distribuyen entre estos extremos, con mayor resolución donde el modelo lo requiera (cerca de la superficie o del fondo).

La dimensión `s_rho` indexa estos niveles: `isel(s_rho=-1)` es el nivel de **superficie** y `isel(s_rho=0)` es el más cercano al **fondo**.

21.4 Mapa de temperatura superficial

```
import numpy as np
import matplotlib.pyplot as plt
import cartopy.crs as ccrs
import cartopy.feature as cfeature

sst = ds['temp'].isel(ocean_time=0, s_rho=-1).values  # array 2D
lon = ds['lon_rho'].values
lat = ds['lat_rho'].values

fig, ax = plt.subplots(figsize=(9, 7),
                        subplot_kw={'projection': ccrs.PlateCarree()})
ax.add_feature(cfeature.COASTLINE, linewidth=0.8)
ax.add_feature(cfeature.LAND, facecolor='lightgray')

pc = ax.pcolormesh(lon, lat, sst, cmap='RdYlBu_r', vmin=8, vmax=20,
                  transform=ccrs.PlateCarree())
plt.colorbar(pc, ax=ax, label='Temperatura (°C)')
ax.set_title('SST - CROCO')
plt.tight_layout()
plt.savefig('sst.png', dpi=150)
```

21.5 Serie temporal en un punto

Para extraer la evolución temporal de una variable en la celda más cercana a una coordenada:

```
import numpy as np

def celda_mas_cercana(ds, lon_target, lat_target):
    """Retorna los índices (eta, xi) de la celda más cercana al punto."""
    lon = ds['lon_rho'].values
    lat = ds['lat_rho'].values
    dist = np.sqrt((lon - lon_target)**2 + (lat - lat_target)**2)
    eta_idx, xi_idx = np.unravel_index(dist.argmin(), dist.shape)
    return int(eta_idx), int(xi_idx)
```

```

eta_i, xi_i = celda_mas_cercana(ds, lon_target=-72.5, lat_target=-41.5)

sst_serie = ds['temp'].isel(s_rho=-1, eta_rho=eta_i, xi_rho=xi_i).values
tiempo    = ds['ocean_time'].values

plt.figure(figsize=(11, 3))
plt.plot(tiempo, sst_serie, lw=0.8, color='steelblue')
plt.ylabel('Temperatura (°C)')
plt.title(f'SST en ({ds["lon_rho"].values[eta_i, xi_i]:.2f}°, '
          f'{ds["lat_rho"].values[eta_i, xi_i]:.2f}°)')
plt.tight_layout()

```

21.6 Perfil vertical: convertir sigma a metros

Para graficar una variable en función de la profundidad real es necesario convertir los niveles sigma. La conversión usa la batimetría local (h), la superficie libre (zeta) y los parámetros del modelo:

```

def sigma_a_profundidad(h, zeta, theta_s, theta_b, hc, N, vtransform=2):
    """
    Calcula la profundidad en metros de cada nivel sigma en un punto.
    Retorna array de longitud N (valores negativos bajo la superficie).
    """
    sc = (1.0 / N) * (np.arange(1, N + 1) - N - 0.5)

    if vtransform == 2:
        csrf = (1 - np.cosh(theta_s * sc)) / (np.cosh(theta_s) - 1)
        csb = (np.exp(theta_b * sc) - 1) / (1 - np.exp(-theta_b))
        Cs = (1 - theta_b) * csrf + theta_b * csb
        z0 = (hc * sc + h * Cs) / (hc + h)
        z = zeta * (1 + z0) + h * z0
    else:
        cff1 = 1.0 / np.sinh(theta_s)
        Cs = (1 - theta_b) * cff1 * np.sinh(theta_s * sc) + \
            theta_b * (0.5 / np.tanh(0.5 * theta_s) *
                      np.tanh(theta_s * (sc + 0.5)) - 0.5)
        z = hc * sc + (h - hc) * Cs + zeta * (1 + hc * sc / h + Cs)
    return z

# Leer parámetros desde los atributos globales del archivo
theta_s = ds.attrs['theta_s']
theta_b = ds.attrs['theta_b']
hc = ds.attrs['hc']
N = ds.dims['s_rho']
vtransform = int(ds.attrs.get('Vtransform', 2))

h_pt = float(ds['h'].values[eta_i, xi_i])

```

```

zeta_pt = float(ds['zeta'].isel(ocean_time=0).values[eta_i, xi_i])
z = sigma_a_profundidad(h_pt, zeta_pt, theta_s, theta_b, hc, N, vtransform)

temp_perfil = ds['temp'].isel(ocean_time=0, eta_rho=eta_i, xi_rho=xi_i).values
salt_perfil = ds['salt'].isel(ocean_time=0, eta_rho=eta_i, xi_rho=xi_i).values

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(8, 6), sharey=True)
ax1.plot(temp_perfil, z, 'o-', color='tomato', ms=4)
ax1.set_xlabel('Temperatura (°C)'); ax1.set_ylabel('Profundidad (m)')
ax2.plot(salt_perfil, z, 'o-', color='steelblue', ms=4)
ax2.set_xlabel('Salinidad (PSU)')
for ax in (ax1, ax2):
    ax.invert_yaxis()
    ax.grid(True, lw=0.5)
plt.suptitle('Perfil T-S')
plt.tight_layout()

```

21.7 Sección transversal

Un corte longitudinal a índice eta_rho constante:

```

eta_corte = 75 # fila de la grilla (latitud fija)

temp_secc = ds['temp'].isel(ocean_time=0, eta_rho=eta_corte).values # (N, xi_rho)
lon_secc = ds['lon_rho'].values[eta_corte, :]
h_secc = ds['h'].values[eta_corte, :]
zeta_secc = ds['zeta'].isel(ocean_time=0).values[eta_corte, :]

# Profundidad real en cada columna: shape (N, xi_rho)
z_secc = np.array([
    sigma_a_profundidad(h_secc[xi], zeta_secc[xi],
                        theta_s, theta_b, hc, N, vtransform)
    for xi in range(len(lon_secc))
]).T

fig, ax = plt.subplots(figsize=(12, 5))
pc = ax.pcolormesh(
    np.tile(lon_secc, (N, 1)),
    z_secc, temp_secc,
    cmap='RdYlBu_r', shading='auto'
)
plt.colorbar(pc, ax=ax, label='Temperatura (°C)')
ax.set_xlabel('Longitud'); ax.set_ylabel('Profundidad (m)')
ax.set_title('Sección de temperatura')
plt.tight_layout()

```

► **Lazy loading y memoria** — `xr.open_dataset` no carga los datos en memoria hasta

que los usas. Si solo necesitas algunas variables, extráelas antes de hacer cálculos:
python temp = ds['temp'].isel(ocean_time=0, s_rho=-1).values # solo aquí lee del disco

► **Múltiples archivos** — CROCO suele generar un archivo por período. Para abrirlos como una sola serie temporal: python ds = xr.open_mfdataset('croco_his_Y*.nc', combine='by_coords')

22 Sentinel-2: API STAC de Copernicus y análisis de cobertura MGRS

Sentinel-2 es el satélite de observación terrestre de la Agencia Espacial Europea (ESA). Tiene un ciclo de revisita de 5 días, captura imágenes a 10 m de resolución en el espectro visible e infrarrojo, y los datos son de libre acceso.

22.1 El sistema de tiles MGRS

Las imágenes Sentinel-2 se organizan en el sistema **MGRS** (*Military Grid Reference System*): una grilla mundial de celdas de 100 km × 100 km identificadas por un código alfanumérico (por ejemplo 19HBB, 18HYE). Cada imagen descargada corresponde a un tile específico. Conocer qué tiles cubren tu zona de estudio es el primer paso antes de buscar o descargar imágenes.

22.2 La API STAC de Copernicus

La plataforma **Copernicus Data Space Ecosystem** (sucesor de SciHub desde 2023) expone su catálogo de imágenes mediante el protocolo **STAC** (*SpatioTemporal Asset Catalog*): un estándar JSON para búsqueda de datos satelitales por área geográfica, período y colección. Solo se necesita Python — sin cuenta, sin Google, sin credenciales para consultar metadatos.

```
pip install pystac-client geopandas matplotlib shapely
```

22.3 Buscar imágenes en un área

```
import pystac_client

client = pystac_client.Client.open(
    "https://catalogue.dataspace.copernicus.eu/stac"
)

# Bounding box: [lon_min, lat_min, lon_max, lat_max]
BBOX = [-73.2, -35.3, -68.8, -31.3] # RM, Valparaíso y O'Higgins

resultados = client.search(
    collections=["sentinel-2-l2a"],
    bbox=BBOX,
    datetime="2024-01-01/2024-01-31",
)
items = list(resultados.items())
print(f"Imágenes encontradas: {len(items)}")
```

22.4 Extraer metadatos de cada imagen

Cada resultado (*item*) tiene propiedades de la escena. Las más útiles:

```
import pandas as pd

registros = []
for item in items:
    p = item.properties
    registros.append({
        "id": item.id,
        "datetime": p.get("datetime"),
        "mgrs_tile": p.get("grid:code", "").replace("MGRS-", ""),
        "cloud_pct": p.get("eo:cloud_cover"),
        "geometry": item.geometry,      # dict GeoJSON con el polígono del tile
    })

df = pd.DataFrame(registros)
df["datetime"] = pd.to_datetime(df["datetime"])
print(df[["datetime", "mgrs_tile", "cloud_pct"]].head(10))
```

Campo	Descripción
mgrs_tile	Código del tile (ej. 19HBB)
cloud_pct	Porcentaje de cobertura de nubes (0-100)
geometry	Polígono del tile en coordenadas geográficas

22.5 Descarga masiva de metadatos: mes a mes

Para un análisis de largo plazo lo eficiente es descargar solo metadatos y guardar un CSV local para no repetir la consulta:

```
import time, json
import pystac_client
import pandas as pd
from datetime import date

BBOX = [-73.2, -35.3, -68.8, -31.3]
AÑOS = [2021, 2022, 2023, 2024]
OUT = "metadata_sentinel2.csv"

client = pystac_client.Client.open(
    "https://catalogue.dataspace.copernicus.eu/stac"
)

registros = []
for year in AÑOS:
    for month in range(1, 13):
        d0 = date(year, month, 1)
```

```

d1 = date(year, month + 1, 1) if month < 12 else date(year + 1, 1, 1)
print(f"{year}-{month:02d}...", end=" ", flush=True)

for intento in range(3):
    try:
        items = list(client.search(
            collections=["sentinel-2-l2a"],
            bbox=BB0X,
            datetime=f"{d0}/{d1}",
        ).items())
        break
    except Exception:
        time.sleep(10 * (intento + 1))
        client = pystac_client.Client.open(
            "https://catalogue.dataspace.copernicus.eu/stac"
        )

print(f"{len(items)} imágenes")
for item in items:
    p = item.properties
    registros.append({
        "year": year,
        "month": month,
        "mgrs_tile": p.get("grid:code", "").replace("MGRS-", ""),
        "cloud_pct": p.get("eo:cloud_cover"),
        "datetime": p.get("datetime"),
        "geometry": json.dumps(item.geometry),
    })

df = pd.DataFrame(registros)
df.to_csv(OUT, index=False)
print(f"Guardado: {OUT} ({len(df)} filas)")

```

22.6 Contar imágenes por tile y mes

```

import pandas as pd

df = pd.read_csv("metadata_sentinel2.csv")

conteo = (df.groupby(["year", "month", "mgrs_tile"])
          .size()
          .reset_index(name="n_images"))

# Tiles con mayor cobertura total
por_tile = df.groupby("mgrs_tile").size().sort_values(ascending=False)
print(por_tile.head(10).to_string())

```

22.7 Intersectar tiles con una región de estudio

Para quedarse solo con los tiles que caen dentro de tu zona de interés:

```
import json, geopandas as gpd
from shapely.geometry import shape
from shapely.ops import unary_union

df = pd.read_csv("metadata_sentinel2.csv")

# Reconstruir polígono real de cada tile (unión de todas sus escenas)
df["geom_obj"] = df["geometry"].apply(lambda g: shape(json.loads(g)))
tile_geoms = df.groupby("mgrs_tile")["geom_obj"].apply(unary_union)

tiles_gdf = gpd.GeoDataFrame({"geometry": tile_geoms}, crs="EPSG:4326")
region_gdf = gpd.read_file("mi_region.geojson") # polígono de la zona de estudio

tiles_en_region = set(
    gpd.sjoin(tiles_gdf, region_gdf[["geometry"]],
              how="inner", predicate="intersects").index.unique()
)
print(f"Tiles dentro de la región: {len(tiles_en_region)}")
```

22.8 Visualizar cobertura mensual en un mapa

```
import matplotlib.pyplot as plt
import geopandas as gpd

mes = df[(df["year"] == 2024) & (df["month"] == 1)]
conteo = mes.groupby("mgrs_tile").size().reset_index(name="n")

tiles_mes = gpd.GeoDataFrame(
    conteo.assign(geometry=conteo["mgrs_tile"].map(tile_geoms)),
    crs="EPSG:4326"
).dropna(subset=["geometry"])

fig, ax = plt.subplots(figsize=(8, 9))
tiles_mes.plot(ax=ax, column="n", cmap="YlOrRd",
               edgecolor="gray", linewidth=0.4, alpha=0.85,
               legend=True, legend_kwds={"label": "Imágenes / tile"})
region_gdf.boundary.plot(ax=ax, edgecolor="steelblue", linewidth=0.8)
ax.set_title("Cobertura Sentinel-2 – Enero 2024")
ax.set_xlabel("Longitud"); ax.set_ylabel("Latitud")
plt.tight_layout()
plt.savefig("cobertura_enero_2024.png", dpi=150)
```

► **Filtrar por nubosidad antes de descargar** — La nubosidad está disponible en los metadatos, lo que permite filtrar antes de descargar cualquier imagen:

```
python df_claras = df[df["cloud_pct"] < 20] print(f"Imágenes con <20% nubes: {len(df_claras)} de {len(df)}")
```

► **Sin cuenta requerida** — La API STAC de Copernicus es pública: no requiere registro para consultar metadatos. La cuenta gratuita en dataspace.copernicus.eu solo es necesaria si se quieren descargar los archivos de imagen completos (.SAFE, .tif).